Введение (1)

Учебный проект состоит из нескольких разделов (блокнотов), в которых последовательно обрабатываются данные, предоставленные организаторами соревнования Catch Me If You Can ("Alice") на платформе Kaggle. В проект входят следующие разделы:

- 1. Введение, подготовка датасетов
- 1. Исследование данных
- 1. Обучение моделей
- 1. Дополнительная глава

При изучении данных материалов важно помнить, что это мой первый опыт как программирования, так и анализа данных :) Буду благодарен каждому совету и указанию на ошибки!

Цель учебного проекта заключается в знакомстве с площадкой Kaggle, получении навыков обработки и визуализации данных, а также изучении основ машинного обучения.

Задача, поставленная передо мной и другими участниками соревнования - задача бинарной классификации. Класс "1" - сессия Alice, класс "0" - все остальные.

О данных

In [1]:
```python
import warnings
warnings.filterwarnings('ignore')
from glob import glob
import os
from tqdm.notebook import tqdm
import numpy as np
import pandas as pd
import scipy.sparse as sp
import pickle

PATH_TO_TRAIN = os.path.join('initial_data', 'train_sessions')
PATH_TO_TEST = os.path.join('initial_data', 'test_sessions')
PATH_TO_DICT = os.path.join('initial_data', 'site_dict')
PATH_TO_DATASET = os.path.join('intermediate_data', 'test_train')
PATH_TO_TRAIN_RAW = os.path.join('initial_data', 'user_logs')
```

Список исходных данных:

- Сырые данные в train.zip (распаковано в папку user_logs) Сырые данные представляют из себя набор (1558 штук, по одному на пользователя) csv-файлов. Каждый файл содержит таблицу из двух столбцов с информацией о последовательности посещённых пользователем сайтов. Например, так выглядят первые три строки файла user_logs/user0002.csv:

```
timestamp,site
2013-11-29 08:14:18,fpdownload2.macromedia.com
2013-11-29 08:14:26,hotmail.fr
...
```

- Подготовленный организаторами соревнования на Kaggle тренировочный набор сессий (сессия - последовательность из 10 сайтов, ограниченная по времени 30 минутами) в train_sessions/train_sessions.csv:

In [2]:
```python
train_df = pd.read_csv(os.path.join(PATH_TO_TRAIN, 'train_sessions.csv'),
                       index_col='session_id', parse_dates=['time' + str(j) for j in range(1,11)])
train_df
```

Out[2]:

session_id	site1	time1	site2	time2	site3	time3	site4	time4	site5	time5	...	time6	site7	time7	site8
1	718	2014-02-20 10:02:45	NaN	NaT	NaN	NaT	NaN	NaT	NaN	NaT	...	NaT	NaN	NaT	NaN
2	890	2014-02-22 11:19:50	941.0	2014-02-22 11:19:50	3847.0	2014-02-22 11:19:51	941.0	2014-02-22 11:19:51	942.0	2014-02-22 11:19:51	...	2014-02-22 11:19:51	3847.0	2014-02-22 11:19:52	3846.0
3	14769	2013-12-16 16:40:17	39.0	2013-12-16 16:40:18	14768.0	2013-12-16 16:40:19	14769.0	2013-12-16 16:40:19	37.0	2013-12-16 16:40:19	...	2013-12-16 16:40:19	14768.0	2013-12-16 16:40:20	14768.0
4	782	2014-03-28 10:52:12	782.0	2014-03-28 10:52:42	782.0	2014-03-28 10:53:12	782.0	2014-03-28 10:53:42	782.0	2014-03-28 10:54:12	...	2014-03-28 10:54:42	782.0	2014-03-28 10:55:12	782.0
5	22	2014-02-28 10:53:05	177.0	2014-02-28 10:55:22	175.0	2014-02-28 10:55:22	178.0	2014-02-28 10:55:23	177.0	2014-02-28 10:55:23	...	2014-02-28 10:55:59	175.0	2014-02-28 10:55:59	177.0
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
253557	3474	2013-11-25 10:26:54	3474.0	2013-11-25 10:26:58	141.0	2013-11-25 10:27:03	2428.0	2013-11-25 10:27:04	106.0	2013-11-25 10:27:13	...	2013-11-25 10:27:16	2428.0	2013-11-25 10:27:28	2428.0
253558	12727	2013-03-12 16:01:15	12727.0	2013-03-12 16:01:16	2215.0	2013-03-12 16:01:16	38.0	2013-03-12 16:01:17	2215.0	2013-03-12 16:01:17	...	2013-03-12 16:01:17	25444.0	2013-03-12 16:01:18	2215.0
253559	2661	2013-09-12 14:05:03	15004.0	2013-09-12 14:05:10	5562.0	2013-09-12 14:05:10	5562.0	2013-09-12 14:06:29	5562.0	2013-09-12 14:06:30	...	NaT	NaN	NaT	NaN
253560	812	2013-12-19 15:20:22	676.0	2013-12-19 15:20:22	814.0	2013-12-19 15:20:22	22.0	2013-12-19 15:20:22	39.0	2013-12-19 15:20:22	...	2013-12-19 15:20:23	814.0	2013-12-19 15:20:23	570.0
253561	34942	2014-04-25 09:56:52	1429.0	2014-04-25 09:56:53	34942.0	2014-04-25 09:56:53	29.0	2014-04-25 09:56:54	30.0	2014-04-25 09:56:54	...	2014-04-25 09:56:54	5779.0	2014-04-25 09:56:54	30.0

253561 rows × 21 columns

In [5]:
```python
train_df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 253561 entries, 1 to 253561
Data columns (total 21 columns):
 #   Column  Non-Null Count   Dtype
---  ------  --------------   -----
 0   site1   253561 non-null  int64
 1   time1   253561 non-null  datetime64[ns]
 2   site2   250098 non-null  float64
 3   time2   250098 non-null  datetime64[ns]
 4   site3   246919 non-null  float64
 5   time3   246919 non-null  datetime64[ns]
 6   site4   244321 non-null  float64
 7   time4   244321 non-null  datetime64[ns]
 8   site5   241829 non-null  float64
 9   time5   241829 non-null  datetime64[ns]
 10  site6   239495 non-null  float64
 11  time6   239495 non-null  datetime64[ns]
 12  site7   237297 non-null  float64
 13  time7   237297 non-null  datetime64[ns]
 14  site8   235224 non-null  float64
 15  time8   235224 non-null  datetime64[ns]
 16  site9   233084 non-null  float64
 17  time9   233084 non-null  datetime64[ns]
 18  site10  231052 non-null  float64
 19  time10  231052 non-null  datetime64[ns]
 20  target  253561 non-null  int64
dtypes: datetime64[ns](10), float64(9), int64(2)
memory usage: 42.6 MB
```

- Подготовленный организаторами тестовый набор сессий в test_sessions/test_sessions.csv:

In [3]:
```python
test_df = pd.read_csv(os.path.join(PATH_TO_TEST, 'test_sessions.csv'),
                      index_col='session_id', parse_dates=['time' + str(j) for j in range(1,11)])
test_df
```

Out[3]:

session_id	site1	time1	site2	time2	site3	time3	site4	time4	site5	time5	site6	time6	site7	time7	site8
1	29	2014-10-04 11:19:53	35.0	2014-10-04 11:19:53	22.0	2014-10-04 11:19:54	321.0	2014-10-04 11:19:54	23.0	2014-10-04 11:19:54	2211.0	2014-10-04 11:19:54	6730.0	2014-10-04 11:19:54	21.0
2	782	2014-07-03 11:00:28	782.0	2014-07-03 11:00:53	782.0	2014-07-03 11:00:58	782.0	2014-07-03 11:01:06	782.0	2014-07-03 11:01:09	782.0	2014-07-03 11:01:10	782.0	2014-07-03 11:01:23	782.0
3	55	2014-12-05 15:55:12	55.0	2014-12-05 15:55:13	55.0	2014-12-05 15:55:14	55.0	2014-12-05 15:56:15	55.0	2014-12-05 15:56:16	55.0	2014-12-05 15:56:17	55.0	2014-12-05 15:56:18	55.0
4	1023	2014-11-04 10:03:19	1022.0	2014-11-04 10:03:19	50.0	2014-11-04 10:03:20	222.0	2014-11-04 10:03:21	202.0	2014-11-04 10:03:21	3374.0	2014-11-04 10:03:22	50.0	2014-11-04 10:03:22	48.0
5	301	2014-05-16 15:05:31	301.0	2014-05-16 15:05:32	301.0	2014-05-16 15:05:33	66.0	2014-05-16 15:05:39	67.0	2014-05-16 15:05:40	69.0	2014-05-16 15:05:40	70.0	2014-05-16 15:05:40	68.0
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
82793	812	2014-10-02 18:20:09	1039.0	2014-10-02 18:20:09	676.0	2014-10-02 18:20:09	NaN	NaT	NaN	NaT	NaN	NaT	NaN	NaT	NaN
82794	300	2014-05-26 14:16:40	302.0	2014-05-26 14:16:41	302.0	2014-05-26 14:16:44	300.0	2014-05-26 14:16:44	300.0	2014-05-26 14:17:19	1222.0	2014-05-26 14:17:19	302.0	2014-05-26 14:17:19	1218.0
82795	29	2014-05-02 11:21:56	33.0	2014-05-02 11:21:56	35.0	2014-05-02 11:21:56	22.0	2014-05-02 11:22:03	37.0	2014-05-02 11:22:03	6779.0	2014-05-02 11:22:03	30.0	2014-05-02 11:22:03	21.0
82796	5828	2014-05-03 10:05:25	23.0	2014-05-03 10:05:27	21.0	2014-05-03 10:05:27	804.0	2014-05-03 10:05:27	21.0	2014-05-03 10:05:36	3350.0	2014-05-03 10:05:37	23.0	2014-05-03 10:05:37	894.0
82797	21	2014-11-02 10:46:57	1098.0	2014-11-02 10:46:57	1098.0	2014-11-02 10:46:58	1098.0	2014-11-02 10:47:12	1098.0	2014-11-02 10:47:13	1098.0	2014-11-02 10:47:14	1098.0	2014-11-02 10:47:15	1098.0

82797 rows × 20 columns

In [4]:
```python
test_df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 82797 entries, 1 to 82797
Data columns (total 20 columns):
 #   Column  Non-Null Count  Dtype
---  ------  --------------  -----
 0   site1   82797 non-null  int64
 1   time1   82797 non-null  datetime64[ns]
 2   site2   81308 non-null  float64
 3   time2   81308 non-null  datetime64[ns]
 4   site3   80075 non-null  float64
 5   time3   80075 non-null  datetime64[ns]
 6   site4   79182 non-null  float64
 7   time4   79182 non-null  datetime64[ns]
 8   site5   78341 non-null  float64
 9   time5   78341 non-null  datetime64[ns]
 10  site6   77566 non-null  float64
 11  time6   77566 non-null  datetime64[ns]
 12  site7   76840 non-null  float64
 13  time7   76840 non-null  datetime64[ns]
 14  site8   76151 non-null  float64
 15  time8   76151 non-null  datetime64[ns]
 16  site9   75484 non-null  float64
 17  time9   75484 non-null  datetime64[ns]
 18  site10  74806 non-null  float64
 19  time10  74806 non-null  datetime64[ns]
dtypes: datetime64[ns](10), float64(9), int64(1)
memory usage: 13.3 MB
```

Подготовка датасетов

В данном блокноте содержатся функции, позволяющие подготовить тренировочный и тестовый наборы данных по образу сформированного организаторами соревнования на Kaggle для дальнейшей визуализации, генерации признаков и тренировки моделей. Это упражнение проделано для формирования навыков предобработки данных.

Подготовка тренировочного набора данных

В данном разделе главная функция, подготавливающая набор данных - prepare_train_set_with_fe. На вход она принимает путь до файлов с информацией о пользователях (path_to_csv_files), путь до словаря с сайтами (path_to_site_dict), а также длину сессии session_length и ширину окна window_size.

In [4]:
```python
def prepare_train_set_with_fe(path_to_csv_files, path_to_site_dict,
                              session_length=10, window_size=10):
    ''' Подготавливает набор данных. Сырые данных хранятся в path_to_csv_files.
    Возвращает DataFrame с сессиями и с несколькими извлеченными признаками
    Внимание! В текущем виде функция плохо работает с другим значением window_size'''

    with open(os.path.join(path_to_site_dict, 'site_dict.pkl'), 'rb') as file:
        site_dict = pickle.load(file)

    data = []

    list_of_files = glob(os.path.join(path_to_csv_files, '*'))
    for path_to_user in tqdm(list_of_files):
        if 'Alice' in path_to_user:
            target = 1
        else:
            target = 0

        sites_array = pd.read_csv(path_to_user)['site'].map(site_dict).values.tolist()
        timestamps = pd.read_csv(path_to_user, parse_dates=['timestamp'])['timestamp']
        time_diffs, ind_reset_generator = timestamps_handling(timestamps)

        try:
            ind_reset = next(ind_reset_generator)
        except StopIteration:
            continue_iter = False
        continue_iter = True
        n = len(sites_array)
        ind = 0

        while True:
            if continue_iter and (ind_reset in range(ind, ind+session_length)):
                '''Если в сессии есть перерыв'''
                sites = sites_array[ind:ind_reset+1]
                times = time_diffs[ind:ind_reset]
                zeros_sites = [0 for _ in range(session_length-len(sites))]
                zeros_times = [0 for _ in range(session_length-len(times) - 1)]
                session = sites + zeros_sites + times + zeros_times

                features = add_features_to_train(timestamps, times, sites, ind)
                data.append(session + features + [target])

                ind = ind_reset + 1
                try:
                    ind_reset = next(ind_reset_generator)
                except StopIteration:
                    continue_iter = False

            else:
                '''Если в сессии нет перерыва'''
                if ind + session_length > n-1:
                    '''Если сессия - последняя сессия пользователя'''
                    sites = sites_array[ind:n]
                    times = time_diffs[ind:n-1]
                    zeros_sites = [0 for _ in range(session_length-len(sites))]
                    zeros_times = [0 for _ in range(session_length-len(times) - 1)]
                    session = sites + zeros_sites + times + zeros_times

                    features = add_features_to_train(timestamps, times, sites, ind)
                    data.append(session + features + [target])

                    ind += window_size
                else:
                    '''Обычная сессия'''
                    sites = sites_array[ind:ind+session_length]
                    times = time_diffs[ind:ind+session_length-1]
                    session = sites + times

                    features = add_features_to_train(timestamps, times, sites, ind)
                    data.append(session + features + [target])

                    ind += window_size

            if ind >= n:
                break

    feature_names=([f'site{i}' for i in range(1, session_length + 1)] +
                   [f'time_diff{i}' for i in range(1, session_length)] +
                   ['session_timespan', '#unique_sites', 'start_hour',
                    'day_of_week', 'day', 'month', 'year',
                    'time', 'time_of_day'] +
                   ['target'])
    data_df = pd.DataFrame(data, columns=feature_names)

    return data_df
```

In [5]:
```python
def timestamps_handling(timestamps):
    ''' Принимает на вход timestamps (pd.Series). Возвращает список с time_diff и
    генератор индексов перерывов (time_diffs >= 1800) '''

    time_diffs = (timestamps[1:].reset_index(drop=True)-
                  timestamps[:-1].reset_index(drop=True)).values

    time_diffs = np.array(time_diffs/1e9, dtype='int') # --> astype(int)

    return time_diffs.tolist(), (i for i in np.where(time_diffs >= 1800)[0])
```

In [6]:
```python
def add_features_to_train(timestamps, times, sites, ind):
    ''' Добавляет основные фичи к тренировочному набору '''

    session_timespan = sum(times)
    num_unique_sites = len(set(sites)-{0})
    start_hour = timestamps[ind].hour
    day_of_week = timestamps[ind].weekday()
    start_day = timestamps[ind].day
    start_month = timestamps[ind].month
    start_year = timestamps[ind].year
    start_time = timestamps[ind].time()
    if timestamps[ind].hour >= 6: time_of_day = 'morning'
    if timestamps[ind].hour >= 12: time_of_day = 'afternoon'
    if timestamps[ind].hour >= 18: time_of_day = 'evening'

    return [session_timespan, num_unique_sites, start_hour,
            day_of_week, start_day, start_month, start_year,
            start_time, time_of_day]
```

In [7]:
```python
%%time
train_s10_w10_m30 = prepare_train_set_with_fe(PATH_TO_TRAIN_RAW, PATH_TO_DICT,
                                              session_length=10, window_size=10)
```

```
Wall time: 2min 30s
```

In [8]:
```python
train_s10_w10_m30
```

Out[8]:

	site1	site2	site3	site4	site5	site6	site7	site8	site9	site10	...	session_timespan	#unique_sites	start_hour	day_of_week	day
0	270	270	270	21	21	7832	21	7832	30	7832	...	437	4	16	1	12
1	29	7832	37	7832	7832	29	7832	29	7832	7832	...	26	3	16	1	12
2	29	7832	7832	29	37	7832	29	7832	29	270	...	53	4	16	1	12
3	167	167	1515	167	37	1514	855	1515	855	1514	...	3	5	16	1	12
4	1516	1515	1514	1518	1521	1523	1519	1524	1517	855	...	0	10	16	1	12
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
252205	3	3	8	3	3	4	4819	8	4819	6	...	15	5	16	0	17
252206	4819	8	41592	14	6	4819	10	14	7	4819	...	2	7	16	0	17
252207	4819	14	11	12	7	3	18	41592	14	4819	...	59	8	16	0	17
252208	11	66	63	8	29	30	162	131	162	29	...	18	8	16	0	17
252209	37	35	30	3	796	0	0	0	0	0	...	2	5	17	0	17

252210 rows × 29 columns

In [9]:
```python
with open(os.path.join(PATH_TO_DATASET, 'train_s10_w10_m30.pkl'), 'wb') as file:
    pickle.dump(train_s10_w10_m30, file)
```

Сформированный из сырых данных тренировочный набор данных получен достаточно быстро (вследствие хорошей оптимизации используемой функции), однако в дальнейшем будет использоваться другой набор данных. Набор данных, на котором будут тренироваться модели, формируется в заключении данного раздела при помощи куда менее эффективной функции.

Подготовка тестового набора данных

In [10]:
```python
test_df = pd.read_csv(os.path.join(PATH_TO_TEST, 'test_sessions.csv'),
                      index_col='session_id', parse_dates=['time' + str(j) for j in range(1,11)])
```

In [11]:
```python
test_df
```

Out[11]:

session_id	site1	time1	site2	time2	site3	time3	site4	time4	site5	time5	site6	time6	site7	time7	site8
1	29	2014-10-04 11:19:53	35.0	2014-10-04 11:19:53	22.0	2014-10-04 11:19:54	321.0	2014-10-04 11:19:54	23.0	2014-10-04 11:19:54	2211.0	2014-10-04 11:19:54	6730.0	2014-10-04 11:19:54	21.0
2	782	2014-07-03 11:00:28	782.0	2014-07-03 11:00:53	782.0	2014-07-03 11:00:58	782.0	2014-07-03 11:01:06	782.0	2014-07-03 11:01:09	782.0	2014-07-03 11:01:10	782.0	2014-07-03 11:01:23	782.0
3	55	2014-12-05 15:55:12	55.0	2014-12-05 15:55:13	55.0	2014-12-05 15:55:14	55.0	2014-12-05 15:56:15	55.0	2014-12-05 15:56:16	55.0	2014-12-05 15:56:17	55.0	2014-12-05 15:56:18	55.0
4	1023	2014-11-04 10:03:19	1022.0	2014-11-04 10:03:19	50.0	2014-11-04 10:03:20	222.0	2014-11-04 10:03:21	202.0	2014-11-04 10:03:21	3374.0	2014-11-04 10:03:22	50.0	2014-11-04 10:03:22	48.0
5	301	2014-05-16 15:05:31	301.0	2014-05-16 15:05:32	301.0	2014-05-16 15:05:33	66.0	2014-05-16 15:05:39	67.0	2014-05-16 15:05:40	69.0	2014-05-16 15:05:40	70.0	2014-05-16 15:05:40	68.0
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
82793	812	2014-10-02 18:20:09	1039.0	2014-10-02 18:20:09	676.0	2014-10-02 18:20:09	NaN	NaT	NaN	NaT	NaN	NaT	NaN	NaT	NaN
82794	300	2014-05-26 14:16:40	302.0	2014-05-26 14:16:41	302.0	2014-05-26 14:16:44	300.0	2014-05-26 14:16:44	300.0	2014-05-26 14:17:19	1222.0	2014-05-26 14:17:19	302.0	2014-05-26 14:17:19	1218.0
82795	29	2014-05-02 11:21:56	33.0	2014-05-02 11:21:56	35.0	2014-05-02 11:21:56	22.0	2014-05-02 11:22:03	37.0	2014-05-02 11:22:03	6779.0	2014-05-02 11:22:03	30.0	2014-05-02 11:22:03	21.0
82796	5828	2014-05-03 10:05:25	23.0	2014-05-03 10:05:27	21.0	2014-05-03 10:05:27	804.0	2014-05-03 10:05:27	21.0	2014-05-03 10:05:36	3350.0	2014-05-03 10:05:37	23.0	2014-05-03 10:05:37	894.0
82797	21	2014-11-02 10:46:57	1098.0	2014-11-02 10:46:57	1098.0	2014-11-02 10:46:58	1098.0	2014-11-02 10:47:12	1098.0	2014-11-02 10:47:13	1098.0	2014-11-02 10:47:14	1098.0	2014-11-02 10:47:15	1098.0

82797 rows × 20 columns

In [12]:
```python
def feature_extracting_from_test(test_df, train=False):
    ''' Преобразует тестовый набор данных в вид, аналогичный тренировочному набору '''

    data_df = test_df.fillna(0)

    sites = ['site' + str(j) for j in range(1,11)]
    times = ['time_diff' + str(j) for j in range(1,10)]
    base_features = ['session_timespan', '#unique_sites',
                     'start_hour', 'day_of_week', 'day',
                     'month', 'year', 'time', 'time_of_day']

    if train is True:
        base_features.append('target')

    new_df = pd.DataFrame(columns=sites + times + base_features,
                          index=range(1, data_df.shape[0] + 1))

    for column in ['site' + str(j) for j in range(1,11)]:
        new_df[column] = data_df[column]

    for j in range(1, 10):
        new_df['time_diff' + str(j)] = (test_df['time' + str(j+1)] -
                                        test_df['time' + str(j)]).apply(lambda x: x.total_seconds())

    new_df['session_timespan'] = new_df.loc[:, 'time_diff1':'time_diff9'].sum(axis=1)

    for i in tqdm(range(1, data_df.shape[0])):
        sites_row = data_df[sites].iloc[i].values
        num_unique_in_session = np.unique(sites_row[sites_row != 0]).shape[0]
        new_df['#unique_sites'][i] = num_unique_in_session

    new_df['start_hour'] = test_df['time1'].apply(lambda x: x.hour)
    new_df['day_of_week'] = test_df['time1'].apply(lambda x: x.weekday())
    new_df['day'] = test_df['time1'].apply(lambda x: x.day)
    new_df['month'] = test_df['time1'].apply(lambda x: x.month)
    new_df['year'] = test_df['time1'].apply(lambda x: x.year)
    new_df['time'] = test_df['time1'].apply(lambda x: x.time())

    def time_of_day(x):
        time_of_day = 'night'
        if x.hour >= 6: time_of_day = 'morning'
        if x.hour >= 12: time_of_day = 'afternoon'
        if x.hour >= 18: time_of_day = 'evening'
        return time_of_day

    new_df['time_of_day'] = data_df['time1'].apply(time_of_day)

    if train is True:
        new_df['target'] = data_df['target']

    return new_df
```

In [13]:
```python
%%time
test_df_final = feature_extracting_from_test(test_df)
```

```
Wall time: 5min 5s
```

In [14]:
```python
test_df_final = test_df_final.fillna(0)
```

In [15]:
```python
test_df_final
```

Out[15]:

	site1	site2	site3	site4	site5	site6	site7	site8	site9	site10	...	time_diff9	session_timespan	#unique_sites
1	29	35.0	22.0	321.0	23.0	2211.0	6730.0	21.0	44582.0	15336.0	...	0.0	7.0	1
2	782	782.0	782.0	782.0	782.0	782.0	782.0	782.0	782.0	782.0	...	23.0	85.0	2
3	55	55.0	55.0	55.0	55.0	55.0	55.0	55.0	1445.0	1445.0	...	3.0	84.0	7
4	1023	1022.0	50.0	222.0	202.0	3374.0	50.0	48.0	48.0	3374.0	...	0.0	4.0	8
5	301	301.0	301.0	66.0	67.0	69.0	70.0	68.0	71.0	167.0	...	4.0	13.0	8
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
82793	812	1039.0	676.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	6
82794	300	302.0	302.0	300.0	300.0	1222.0	302.0	1218.0	1221.0	1216.0	...	0.0	39.0	10
82795	29	33.0	35.0	22.0	37.0	6779.0	30.0	21.0	23.0	6780.0	...	0.0	8.0	7
82796	5828	23.0	21.0	804.0	21.0	3350.0	23.0	894.0	21.0	961.0	...	0.0	13.0	2
82797	21	1098.0	1098.0	1098.0	1098.0	1098.0	1098.0	1098.0	1098.0	1098.0	...	5.0	50.0	0

82797 rows × 28 columns

In [16]:
```python
with open(os.path.join(PATH_TO_DATASET, 'test_s10_w10_m30_final.pkl'), 'wb') as file:
    pickle.dump(test_df_final, file)
```

Замечание! Модели, натренированные в разделе "Тренировка моделей" на полученном в этом разделе вручную тренировочном наборе, выдают меньший score на публичном тестовом наборе данных, чем при использовании сформированного организаторами тестового набора данных. Здесь будет применена функция feature_extracting_from_test с параметром train=True к сформированному организаторами набору данных train_sessions.csv. К сожалению, данная функция неоптимизирована и работает существенно дольше той, что собирает датасет из сырых данных.

In [17]:
```python
train_df = pd.read_csv(os.path.join(PATH_TO_TRAIN, 'train_sessions.csv'),
                       index_col='session_id', parse_dates=['time' + str(j) for j in range(1,11)])
```

In [18]:
```python
train_df
```

Out[18]:

session_id	site1	time1	site2	time2	site3	time3	site4	time4	site5	time5	...	time6	site7	time7	site8
1	718	2014-02-20 10:02:45	NaN	NaT	NaN	NaT	NaN	NaT	NaN	NaT	...	NaT	NaN	NaT	NaN
2	890	2014-02-22 11:19:50	941.0	2014-02-22 11:19:50	3847.0	2014-02-22 11:19:51	941.0	2014-02-22 11:19:51	942.0	2014-02-22 11:19:51	...	2014-02-22 11:19:51	3847.0	2014-02-22 11:19:52	3846.0
3	14769	2013-12-16 16:40:17	39.0	2013-12-16 16:40:18	14768.0	2013-12-16 16:40:19	14769.0	2013-12-16 16:40:19	37.0	2013-12-16 16:40:19	...	2013-12-16 16:40:19	14768.0	2013-12-16 16:40:20	14768.0
4	782	2014-03-28 10:52:12	782.0	2014-03-28 10:52:42	782.0	2014-03-28 10:53:12	782.0	2014-03-28 10:53:42	782.0	2014-03-28 10:54:12	...	2014-03-28 10:54:42	782.0	2014-03-28 10:55:12	782.0
5	22	2014-02-28 10:53:05	177.0	2014-02-28 10:55:22	175.0	2014-02-28 10:55:22	178.0	2014-02-28 10:55:23	177.0	2014-02-28 10:55:23	...	2014-02-28 10:55:59	175.0	2014-02-28 10:55:59	177.0
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
253557	3474	2013-11-25 10:26:54	3474.0	2013-11-25 10:26:58	141.0	2013-11-25 10:27:03	2428.0	2013-11-25 10:27:04	106.0	2013-11-25 10:27:13	...	2013-11-25 10:27:16	2428.0	2013-11-25 10:27:28	2428.0
253558	12727	2013-03-12 16:01:15	12727.0	2013-03-12 16:01:16	2215.0	2013-03-12 16:01:16	38.0	2013-03-12 16:01:17	2215.0	2013-03-12 16:01:17	...	2013-03-12 16:01:17	25444.0	2013-03-12 16:01:18	2215.0
253559	2661	2013-09-12 14:05:03	15004.0	2013-09-12 14:05:10	5562.0	2013-09-12 14:05:10	5562.0	2013-09-12 14:06:29	5562.0	2013-09-12 14:06:30	...	NaT	NaN	NaT	NaN
253560	812	2013-12-19 15:20:22	676.0	2013-12-19 15:20:22	814.0	2013-12-19 15:20:22	22.0	2013-12-19 15:20:22	39.0	2013-12-19 15:20:22	...	2013-12-19 15:20:23	814.0	2013-12-19 15:20:23	570.0
253561	34942	2014-04-25 09:56:52	1429.0	2014-04-25 09:56:53	34942.0	2014-04-25 09:56:53	29.0	2014-04-25 09:56:54	30.0	2014-04-25 09:56:54	...	2014-04-25 09:56:54	5779.0	2014-04-25 09:56:54	30.0

253561 rows × 21 columns

In [19]:
```python
%%time
train_df_final = feature_extracting_from_test(train_df, train=True)
```

```
Wall time: 39min
```

In [20]:
```python
train_df_final = train_df_final.fillna(0)
```

In [21]:
```python
with open(os.path.join(PATH_TO_DATASET, 'train_s10_w10_m30_final.pkl'), 'wb') as file:
    pickle.dump(train_df_final, file)
```

В результате выполнения кода из данного блокнота будут сформированы несколько файлов. В дальнейшем будут использоваться следующие:

- test_train/train_s10_w10_m30.pkl
- test_train/train_s10_w10_m30_final.pkl
- test_train/test_s10_w10_m30_final.pkl

Исследование данных (2)

Результатом предыдущего блокнота стали два набора данных с некоторым количеством извлечённых признаков. В данном блокноте эти признаки исследуются и строятся новые.

In [24]:
```python
import os
import warnings
warnings.filterwarnings('ignore')

import pickle
import numpy as np
import pandas as pd
import seaborn as sns
import re
from matplotlib import pyplot as plt

PATH_TO_DATASET = os.path.join('intermediate_data', 'test_train')
PATH_TO_DICT = os.path.join('initial_data', 'site_dict')
```

In [25]:
```python
with open(os.path.join(PATH_TO_DATASET, 'train_s10_w10_m30_final.pkl'), 'rb') as f:
    train_df = pickle.load(f)

train_df = train_df.sort_values(by=['year', 'month', 'day', 'time'])
y_train = train_df['target'].astype('int').values
```

Взглянем на подготовленный DataFrame.

In [26]:
```python
train_df
```

Out[26]:

	site1	site2	site3	site4	site5	site6	site7	site8	site9	site10	...	session_timespan	#unique_sites	start_hour
21669	56	55.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	8	8
54843	56	55.0	56.0	55.0	0.0	0.0	0.0	0.0	0.0	0.0	...	1786.0	4	8
77292	946	946.0	951.0	946.0	946.0	945.0	948.0	784.0	949.0	946.0	...	4.0	7	8
114021	945	948.0	949.0	948.0	945.0	946.0	947.0	945.0	946.0	946.0	...	3.0	4	8
146670	947	950.0	948.0	947.0	950.0	952.0	946.0	951.0	946.0	947.0	...	2.0	5	8
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
12224	50	50.0	48.0	49.0	48.0	52.0	52.0	49.0	303.0	304.0	...	12.0	6	23
164438	4207	753.0	753.0	52.0	50.0	4207.0	3346.0	3359.0	3346.0	38.0	...	178.0	5	23
12221	52	3346.0	784.0	784.0	3346.0	979.0	3324.0	7330.0	3594.0	3329.0	...	28.0	5	23
156968	3328	3324.0	3599.0	3413.0	753.0	3328.0	3599.0	3359.0	3359.0	3346.0	...	77.0	8	23
204762	222	3346.0	3346.0	3359.0	55.0	2891.0	3346.0	0.0	0.0	0.0	...	12.0	2	23

253561 rows × 29 columns

Временные признаки

1. Время начала сессии.

Первый временной признак, который может оказаться интересным - время начала сессии. Если Alice придерживается определённого расписания, это поможет классификации.

In [27]:
```python
session_start_hour = train_df['start_hour'].values
```

In [28]:
```python
plt.subplots(1, 2, figsize = (15, 6))

plt.subplot(1, 2, 1)
ax = sns.countplot(session_start_hour[y_train == 1])
ax.set(title='Alice',
       xlabel='start_hour')

plt.subplot(1, 2, 2)
ax = sns.countplot(session_start_hour[y_train == 0])
ax.set(title='not Alice',
       xlabel='start_hour');
```

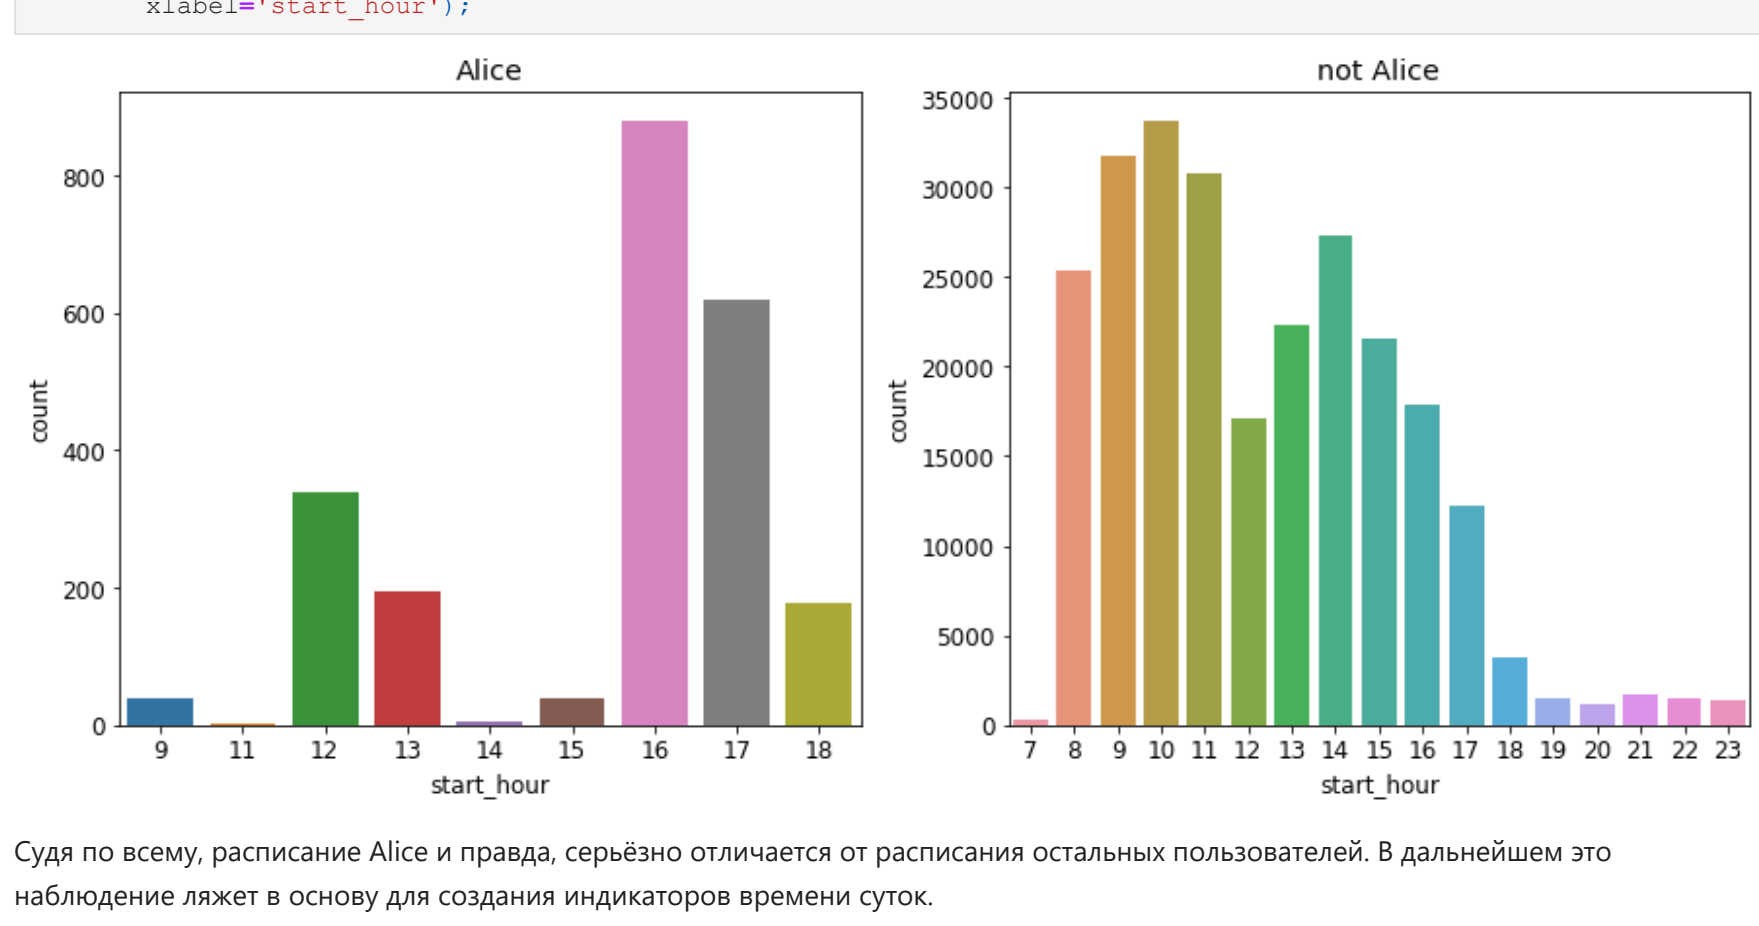

Судя по всему, расписание Alice и правда, серьёзно отличается от расписания остальных пользователей. В дальнейшем это наблюдение ляжет в основу для создания индикаторов времени суток.

1. День недели

Второй временной признак, который может оказаться интересным - день недели, в который данная сессия наблюдалась.

In [29]:
```python
session_day_of_week = train_df['day_of_week'].values
```

In [30]:
```python
plt.subplots(1, 2, figsize = (15, 6))

plt.subplot(1, 2, 1)
ax = sns.countplot(session_day_of_week[y_train == 1])
ax.set(xlabel='day_of_week',
       title='Alice',
       xticklabels=['Mon','Tue','Wed','Thu','Fri','Sat','Sun'])

plt.subplot(1, 2, 2)
ax = sns.countplot(session_day_of_week[y_train == 0])
ax.set(xlabel='day_of_week',
       title='not Alice',
       xticklabels=['Mon','Tue','Wed','Thu','Fri','Sat','Sun']);
```

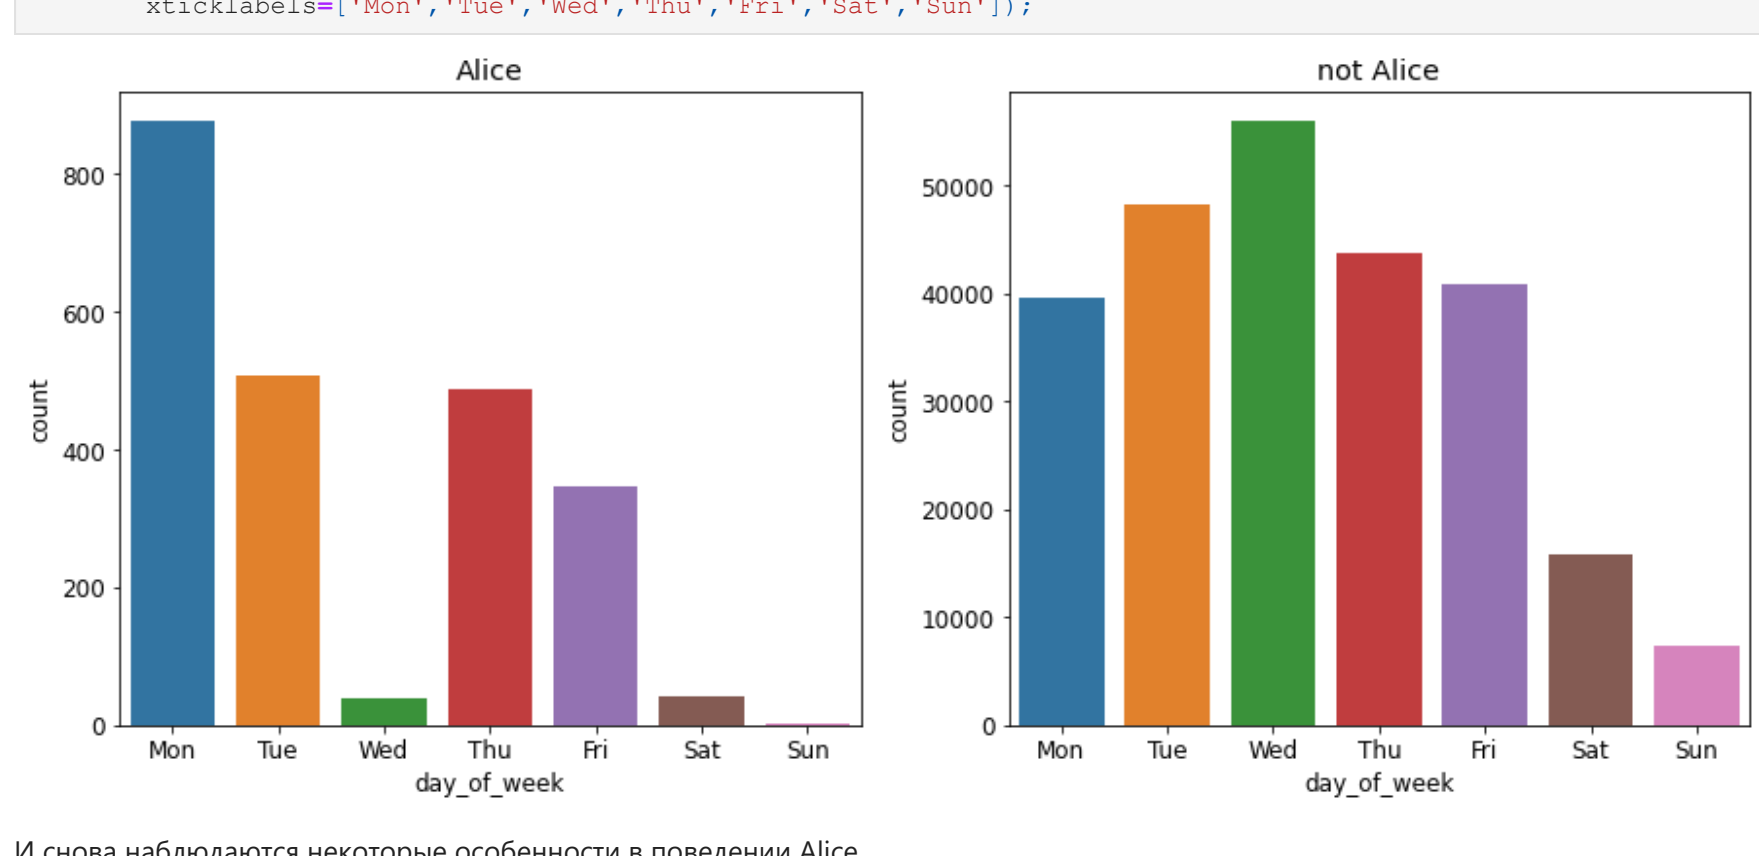

И снова наблюдаются некоторые особенности в поведении Alice.

1. Продолжительность сессии

Третий временной признак, который может оказаться интересным - продолжительность сессии.

In [31]:
```python
session_timespan = train_df['session_timespan'].values
```

Посмотрим на некоторые характеристики продолжительности сессии в наборах данных.

In [32]:
```python
print(
    '>>> ТРЕНИРОВОЧНЫЙ НАБОР ДАННЫХ\n'
    f'Максимальная продолжительность сессии: {round(session_timespan[y_train == 0].max())}\n'
    f'Минимальная продолжительность сессии: {round(session_timespan[y_train == 0].min())}\n'
    f'Средняя продолжительность сессии: {round(session_timespan[y_train == 0].mean())}\n'
    f'25% - квантиль продолжительности сессии: {round(np.quantile(session_timespan[y_train == 0], 0.25))}\n'
    f'50% - квантиль продолжительности сессии: {round(np.quantile(session_timespan[y_train == 0], 0.50))}\n'
    f'75% - квантиль продолжительности сессии: {round(np.quantile(session_timespan[y_train == 0], 0.75))}\n'
    f'95% - квантиль продолжительности сессии: {round(np.quantile(session_timespan[y_train == 0], 0.95))}\n'
    f'99% - квантиль продолжительности сессии: {round(np.quantile(session_timespan[y_train == 0], 0.99))}\n')
```

```
>>> ТРЕНИРОВОЧНЫЙ НАБОР ДАННЫХ
Максимальная продолжительность сессии: 1800
Минимальная продолжительность сессии: 0
Средняя продолжительность сессии: 139
25% - квантиль продолжительности сессии: 7
50% - квантиль продолжительности сессии: 28
75% - квантиль продолжительности сессии: 114
95% - квантиль продолжительности сессии: 786
99% - квантиль продолжительности сессии: 1610
```

In [33]:
```python
print(
    '>>> НАБОР ДАННЫХ ДЛЯ ALICE\n'
    f'Максимальная продолжительность сессии: {round(session_timespan[y_train == 1].max())}\n'
    f'Минимальная продолжительность сессии: {round(session_timespan[y_train == 1].min())}\n'
    f'Средняя продолжительность сессии: {round(session_timespan[y_train == 1].mean())}\n'
    f'25% - квантиль продолжительности сессии: {round(np.quantile(session_timespan[y_train == 1], 0.25))}\n'
    f'50% - квантиль продолжительности сессии: {round(np.quantile(session_timespan[y_train == 1], 0.50))}\n'
    f'75% - квантиль продолжительности сессии: {round(np.quantile(session_timespan[y_train == 1], 0.75))}\n'
    f'95% - квантиль продолжительности сессии: {round(np.quantile(session_timespan[y_train == 1], 0.95))}\n'
    f'99% - квантиль продолжительности сессии: {round(np.quantile(session_timespan[y_train == 1], 0.99))}\n')
```

```
>>> НАБОР ДАННЫХ ДЛЯ ALICE
Максимальная продолжительность сессии: 1763
Минимальная продолжительность сессии: 0
Средняя продолжительность сессии: 52
25% - квантиль продолжительности сессии: 4
50% - квантиль продолжительности сессии: 11
75% - квантиль продолжительности сессии: 38
95% - квантиль продолжительности сессии: 203
99% - квантиль продолжительности сессии: 827
```

In [34]:
```python
import matplotlib
font = {'size': 12}
matplotlib.rc('font', **font)

plt.subplots(1, 2, figsize = (15, 6))

plt.subplot(1, 2, 1)
ax = sns.boxplot(np.log10(session_timespan[y_train == 0]))
ax.set(xlabel='session_timespan',
       title='not Alice');

plt.subplot(1, 2, 2)
ax = sns.boxplot(np.log10(session_timespan[y_train == 1]))
ax.set(xlabel='session_timespan',
       title='Alice');
```

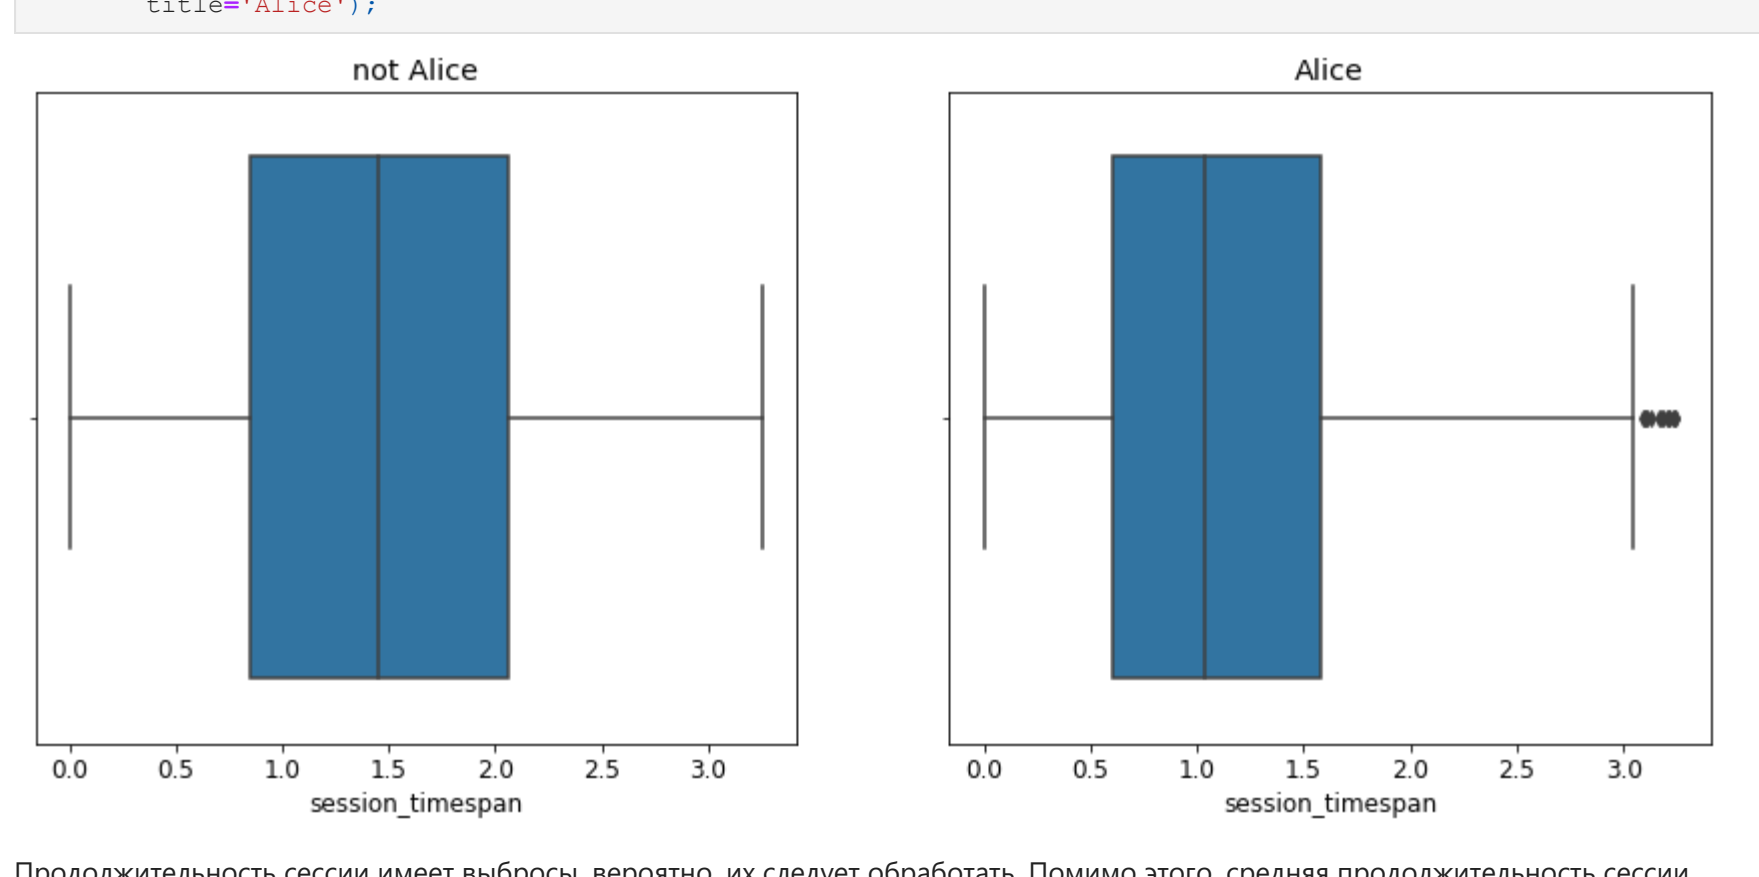

Продолжительность сессии имеет выбросы, вероятно, их следует обработать. Помимо этого, средняя продолжительность сессии Alice заметно меньше. Это будет использовано при дальнейшем построении признаков.

Хотелось бы использовать не только признак "Продолжительность сессии" как таковой, но также попытаться выделить характерные для Alice продолжительности. Для этого проведём более тонкий анализ.

In [35]:
```python
plt.subplots(ncols=1, nrows=2, figsize = (14, 14))

plt.subplot(2, 1, 1)
ax = sns.histplot(session_timespan[y_train == 1],
                  binwidth=1,
                  binrange=(0, 100),
                  stat="density"
                 )
ax.set(xlabel='session_timespan',
       title='Alice')

plt.subplot(2, 1, 2)
ax = sns.histplot(session_timespan[y_train == 0],
                  binwidth=1,
                  binrange=(0, 100),
                  stat="density")
ax.set(xlabel='session_timespan',
       title='not Alice');
```

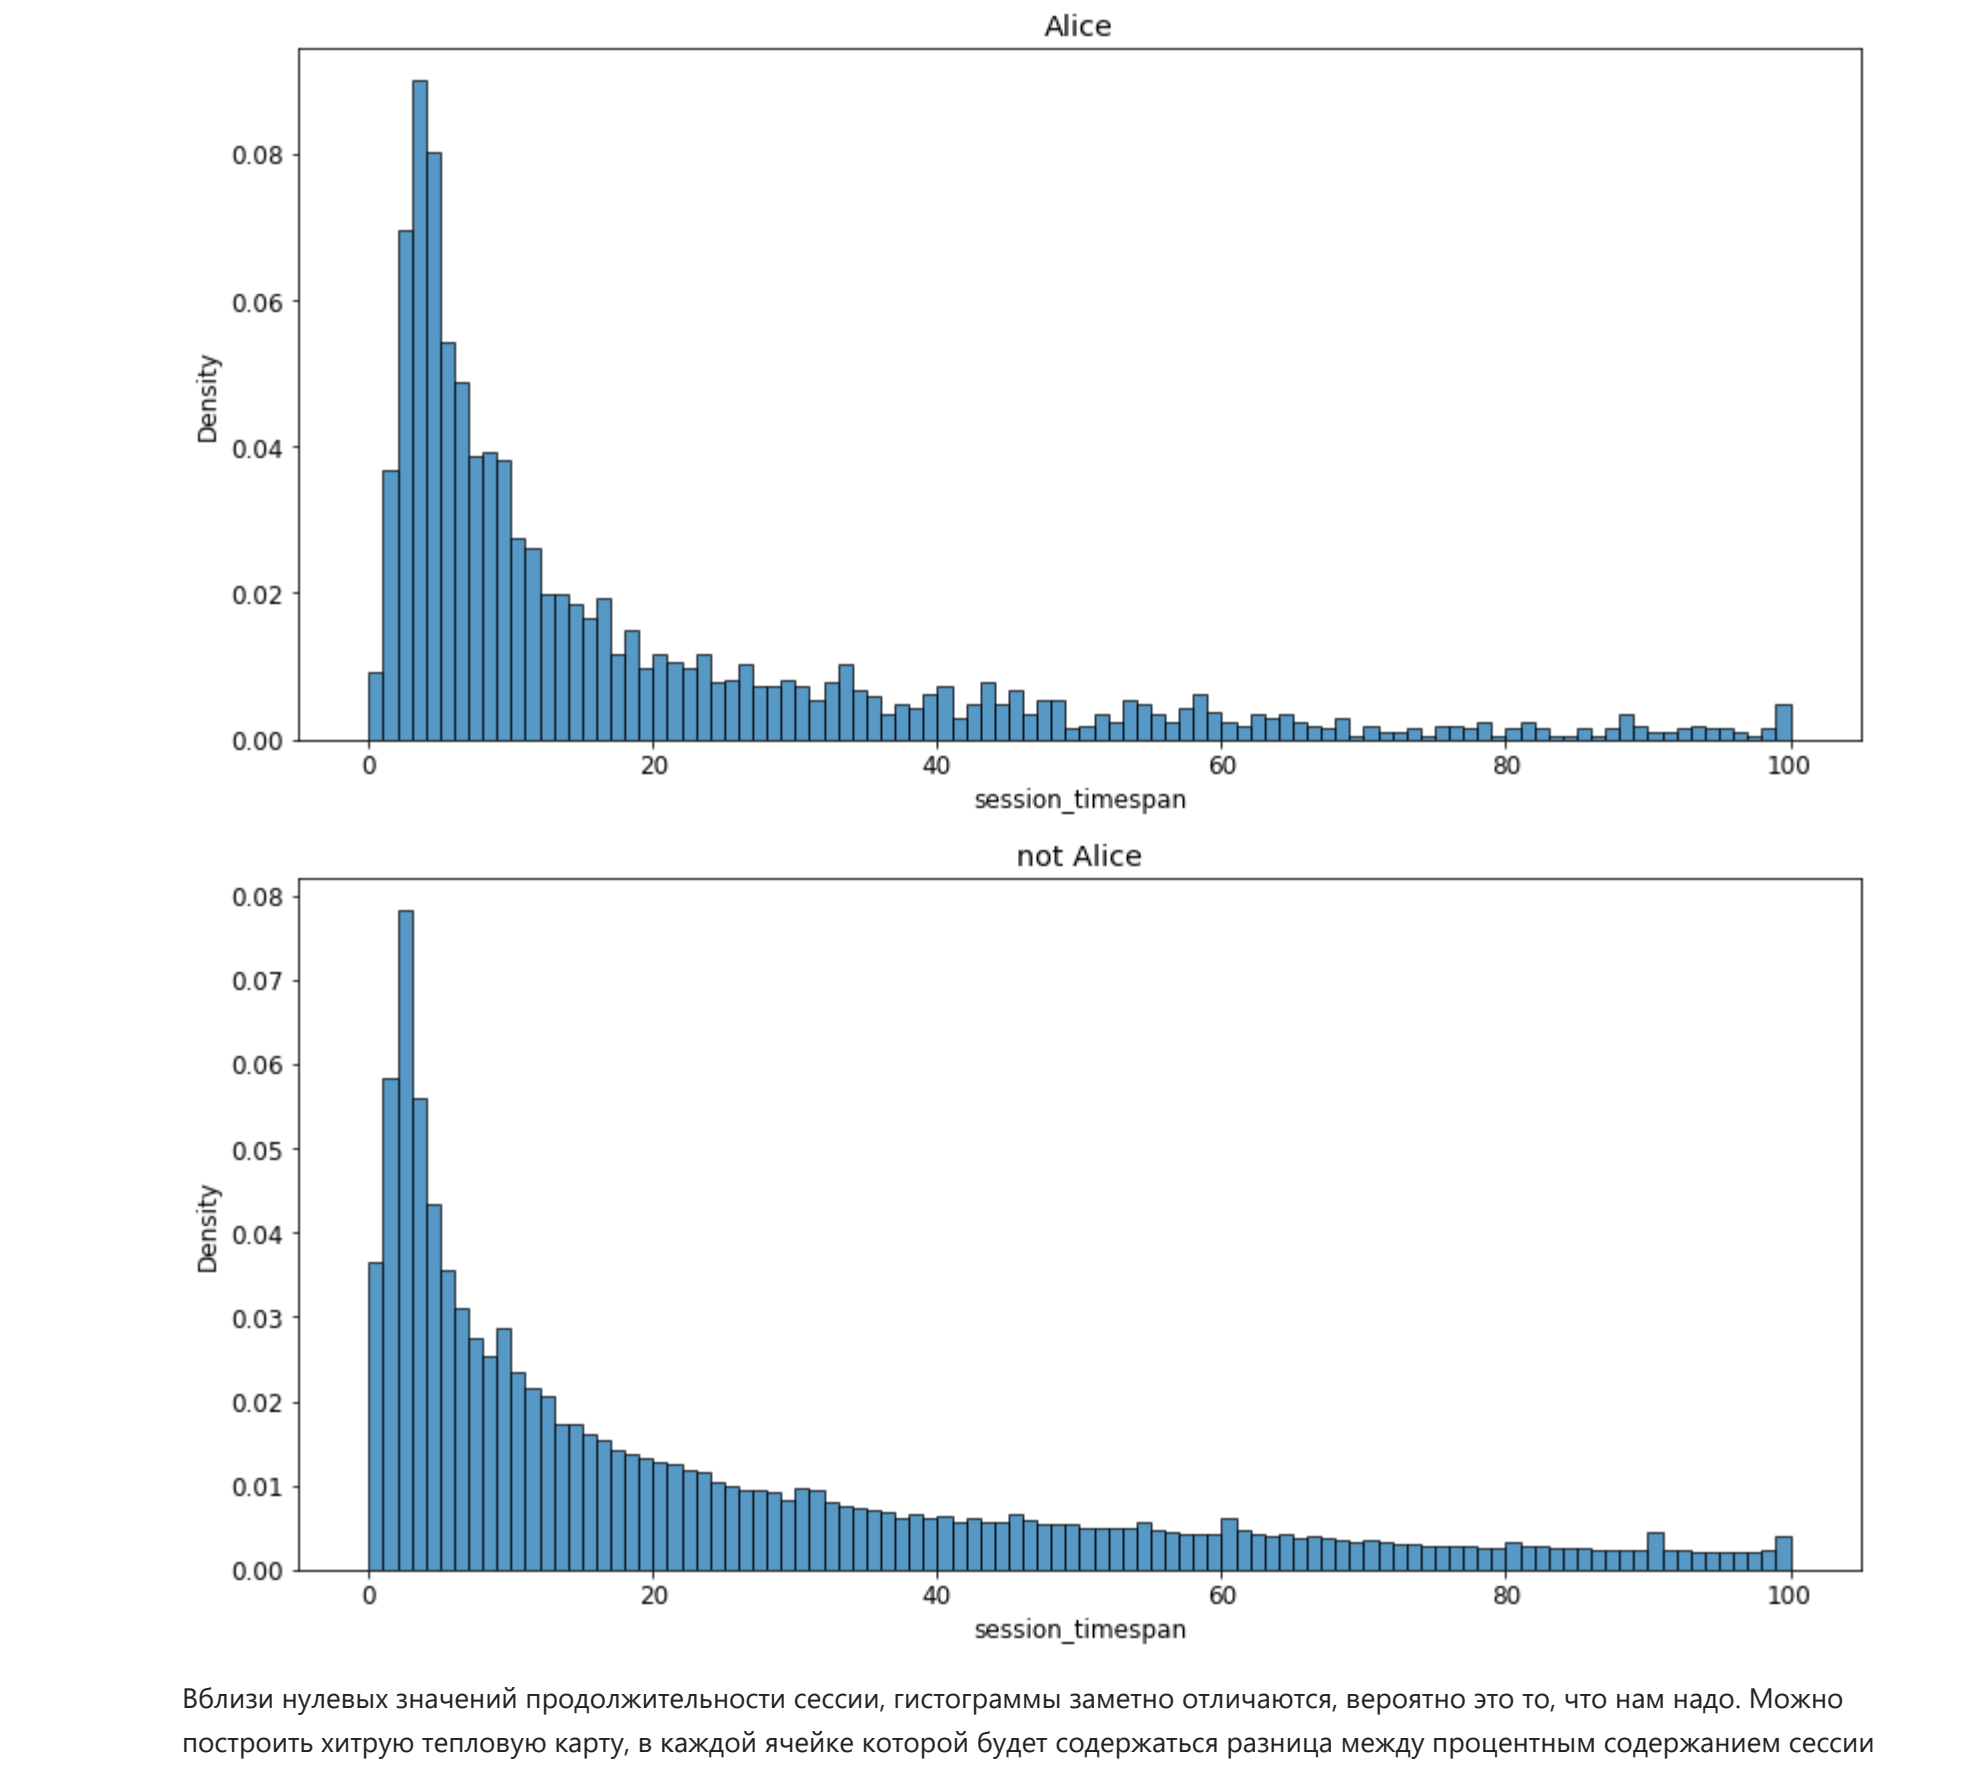

Вблизи нулевых значений продолжительности сессии, гистограммы заметно отличаются, вероятно это то, что нам надо. Можно построить хитрую тепловую карту, в каждой ячейке которой будет содержаться разница между процентным содержанием сессии данной продолжительности у Alice и у всех, кроме Alice.

Например, сессия с продолжительностью 0 секунд в наборе сессий у Alice встречается в 0.83% всех сессий, а у всех, кроме Alice в 2.61%, значит, разница для сессий продолжительностью 0 секунд равна -1.78%. Это может, например, означать, что Alice меньше других склонна открывать много вкладок за раз.

При необходимости, в определённую ниже функцию per_difference_heatmap можно передавать количество секунд для группировки.

In [36]:
```
def per_difference_heatmap(seconds_to_group=1):
    ''' Строит heatmap для разницы продолжительности сессии (Alice - not Alice)
    Положительные значения означают, что сессия Alice чаще других имеет данную
    продолжительность. При необходимости можно изменять временное окно (seconds_to_group)'''
    start_second = 0
    stop_second = 100 * seconds_to_group

    def session_timespan_info(df, bins):
        times = df['session_timespan'].values
        result = []
        for i in range(len(bins)-1):
            result.append(times[(times >= bins[i]) & (times  < bins[i+1])].shape[0])
        return np.array(result)

    bins = [i for i in range(start_second, stop_second, seconds_to_group)]
    times_alice = session_timespan_info(train_df[train_df['target'] == 1], bins)
    times_not_alice = session_timespan_info(train_df[train_df['target'] == 0], bins)

    alice_percentage = times_alice/train_df[train_df['target'] == 1].shape[0] * 100
    not_alice_percentage = times_not_alice/train_df[train_df['target'] == 0].shape[0] * 100
    difference = alice_percentage - not_alice_percentage

    print(f'Минимальная разница: {round(difference.min(), 1)} %')
    print(f'Максимальная разница: {round(difference.max(), 1)} %')

    print(f'\n\033[1mПоложительные значения означают, что сессия Alice чаще других имеет данную продолжительнос
    plt.subplots(1, 1, figsize = (14, 6))
    labels = np.array([f'{round(diff, 1)}%\n          {sec*seconds_to_group}s'
                      for sec, diff in enumerate(difference[:66])]).reshape(-1, 11)
    sns.heatmap(data=difference[:66].reshape(-1, 11),
                annot=labels, xticklabels=False,
                yticklabels=False, cbar=False, fmt='')


per_difference_heatmap(seconds_to_group=1)
```

```
Минимальная разница: -1.8 %
Максимальная разница: 4.1 %
```

Положительные значения означают, что сессия Alice чаще других имеет данную продолжительность

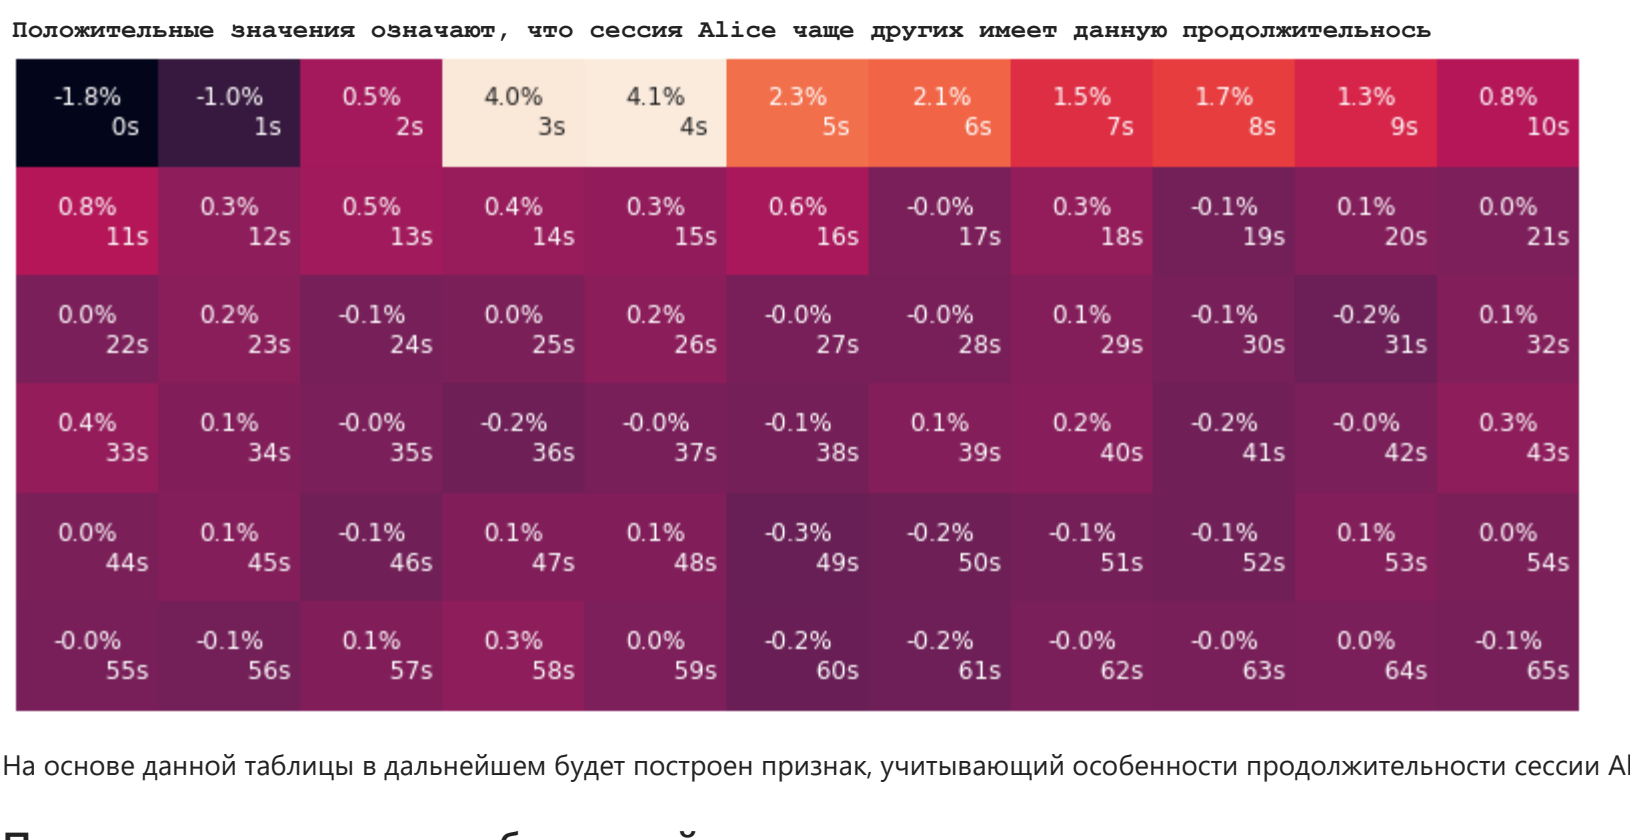

На основе данной таблицы в дальнейшем будет построен признак, учитывающий особенности продолжительности сессии Alice.

Признаки, связанные с набором сайтов в сессии

Следующая группа признаков, которая может нас заинтересовать связана с набором сайтов в сессии. Подавляющее большинство признаков этой группы будет порождено вдальнейшем в виде матрицы частот с помощью CountVectorizer (или TfidfVectorizer), здесь же будут исследованы остальные признаки, которые могут быть извлечены из наборов сайтов в сессии.

1. Количество уникальных сайтов в сессии

Возможно, отличить Alice от остальных, количество различных сайтов, которые она использует в пределах одной сессии.

In [37]:
```
num_unique_sites = train_df['#unique_sites'].values
```

In [38]:
```
plt.subplots(1, 2, figsize = (15, 6))

plt.subplot(1, 2, 1)
ax = sns.countplot(num_unique_sites[y_train == 1])
ax.set(title='Alice',
       xlabel='#unique_sites')

plt.subplot(1, 2, 2)
ax = sns.countplot(num_unique_sites[y_train == 0])
ax.set(title='not Alice',
       xlabel='#unique_sites');
```

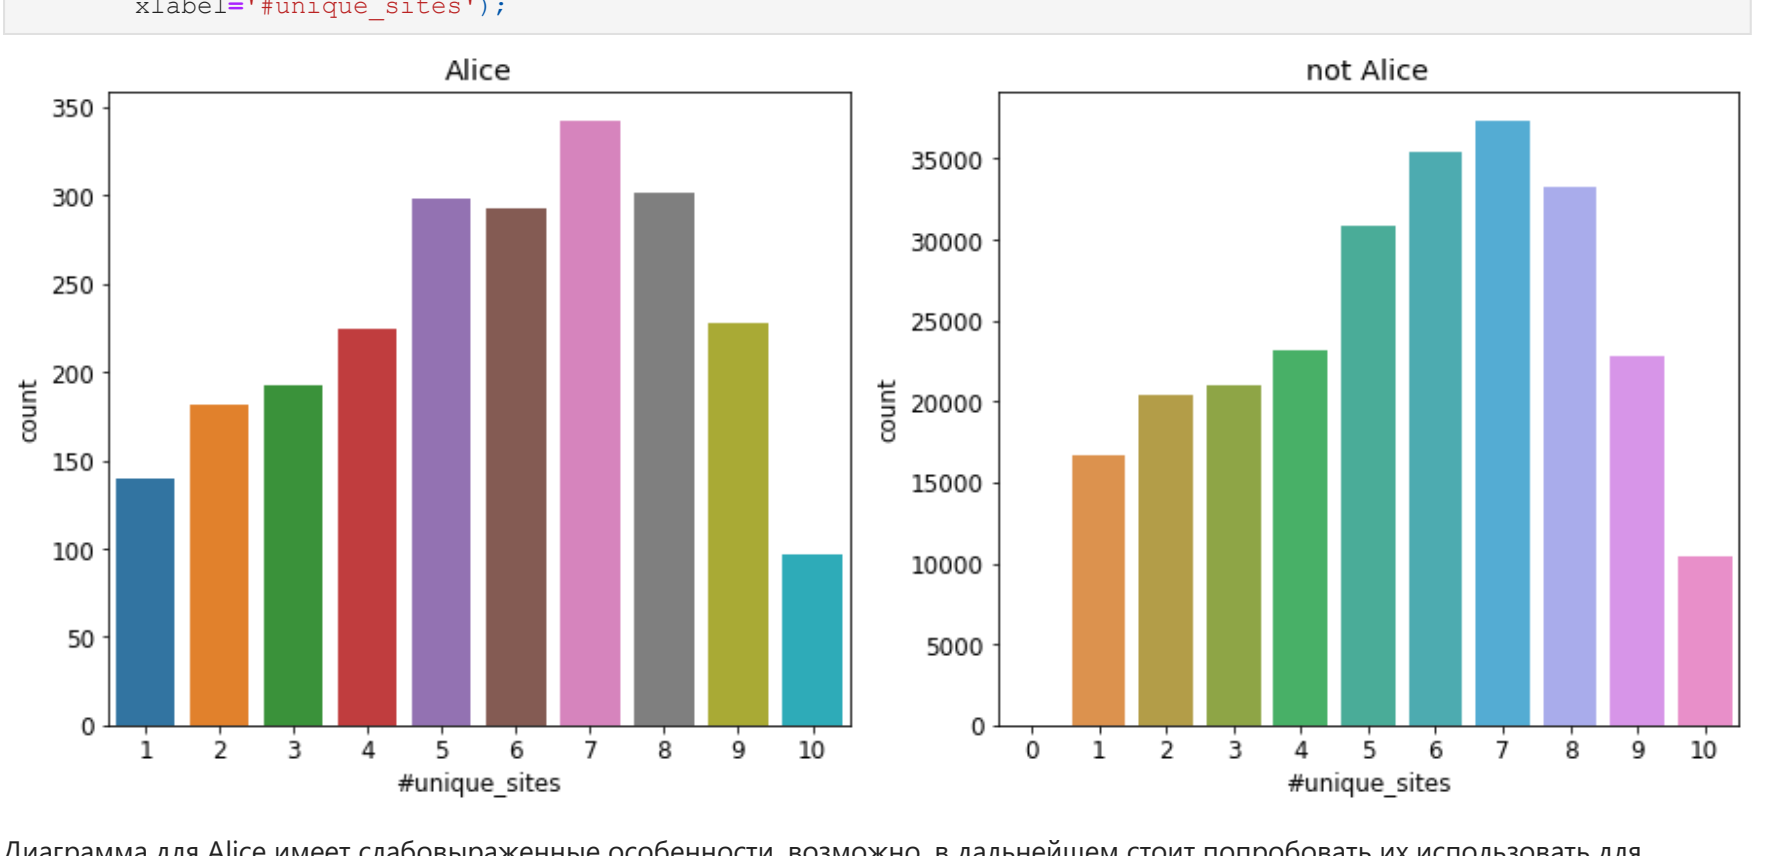

Диаграмма для Alice имеет слабовыраженные особенности, возможно, в дальнейшем стоит попробовать их использовать для построения признаков.

1. Сайты, встречающиеся чаще в сессии Alice, чем в сессиях других пользователей и наоборот

В дальнейшем хотелось бы создать несколько признаков-идикаторов или счетчиков для определённых сайтов в сессии, наличие или количество которых могло бы дополнительно повысить качество классификации.

In [39]:
```
def attendance_list(df, target):
    '''Вспомогательная функция. Возвращает топ сайтов (id сайта, количество посещений)'''

    ind, cnt = np.unique(df[df['target'] == target]
                         [['site%s' % i for i in range(1, 11)]].values.ravel(), return_counts=True)
    ind_cnt = np.hstack((ind.reshape(-1,1), cnt.reshape(-1,1))).tolist()
    ind_cnt.sort(key=lambda x: x[1], reverse=True)
    return ind_cnt
```

In [40]:
```
def out_of_popular_sites(alice_first, not_alice_first, top_alice):
    ''' Возвращает множество сайтов, входящих в топ-Alice, но не входящие в топ-not_Alice (top_alice=True).
        Либо возвращает множество сайтов, входящих в топ-not_Alice, но не входящие в топ-Alice (top_alice=False

    alice_top = attendance_list(train_df, target=1)[:alice_first]
    all_top = attendance_list(train_df, target=0)[:not_alice_first]

    set_alice_top = set([site[0] for site in alice_top])
    set_not_alice_top = set([site[0] for site in all_top])
    if top_alice is True:
        return set_alice_top - set_not_alice_top
    if top_alice is False:
        return set_not_alice_top - set_alice_top
```

In [41]:
```
for_check = [(100, 3900), (60, 1000), (60, 2200), (20, 150), (10, 45), (10, 40), (5, 20)]

for alice_first, not_alice_first in for_check:
    print(f'Среди топ-{alice_first} сайтов Alice, сайты, которые не входят в топ-{not_alice_first}: '
          f'{out_of_popular_sites(alice_first, not_alice_first, top_alice=True)}')
```

```
Среди топ-100 сайтов Alice, сайты, которые не входят в топ-3900: {27307.0, 27172.0, 27189.0, 25383.0}
Среди топ-60 сайтов Alice, сайты, которые не входят в топ-1000: {2080.0, 12619.0, 27307.0, 263.0}
Среди топ-60 сайтов Alice, сайты, которые не входят в топ-2200: {27307.0}
Среди топ-20 сайтов Alice, сайты, которые не входят в топ-150: {3000.0}
Среди топ-10 сайтов Alice, сайты, которые не входят в топ-45: {81.0, 82.0}
Среди топ-10 сайтов Alice, сайты, которые не входят в топ-40: {81.0, 82.0, 879.0}
Среди топ-5 сайтов Alice, сайты, которые не входят в топ-20: {77.0}
```

In [42]:
```
for_check = [(100, 30), (100, 20), (100, 10), (100, 5)]

for alice_first, not_alice_first in for_check:
    print(f'Среди топ-{not_alice_first} сайтов, сайты, которые не входят в топ-{alice_first} сайтов Alice: '
          f'{out_of_popular_sites(alice_first, not_alice_first, top_alice=False)}')
```

```
Среди топ-30 сайтов, сайты, которые не входят в топ-100 сайтов Alice: {778.0, 780.0, 812.0, 782.0, 786.0, 55.0,
56.0, 570.0}
Среди топ-20 сайтов, сайты, которые не входят в топ-100 сайтов Alice: {778.0, 780.0, 812.0, 782.0, 786.0, 55.0,
570.0}
Среди топ-10 сайтов, сайты, которые не входят в топ-100 сайтов Alice: {778.0, 780.0, 782.0}
Среди топ-5 сайтов, сайты, которые не входят в топ-100 сайтов Alice: {782.0}
```

Заметим, что имеется ряд сайтов, которые Alice посещает чаще, чем остальные люди в наборе данных. Также, имеются и такие сайты, которые Alice посещает реже, чем остальные люди. В дальнейшем будут сформированы два признака-индикатора вхождения одного из интересующих сайтов в сессию.

Посмотрим на сайты, обнаруженные таким образом

In [43]:
```
with open(os.path.join(PATH_TO_DICT, 'site_dict.pkl'), 'rb') as file:
    sites_dict = pickle.load(file)
reversed_dict = {v: k for k, v in sites_dict.items()}
reversed_dict[0] = '0'
```

In [44]:
```
sites_top_alice = {3000, 2080, 27307, 12619, 263, 25383, 81, 81, 879, 77}
sites_top_not_alice = {55, 56, 570, 778, 780, 782, 786, 812}

print('\033[1m Alice \033[0m\n')
for site in sites_top_alice:
    print(f'{site}: {reversed_dict[site]}')

print('\n\033[1m not Alice \033[0m\n')
for site in sites_top_not_alice:
    print(f'{site}: {reversed_dict[site]}')
```

Alice

```
2080: media-1.melty.fr
263: www.caf.fr
25383: www.cjn.justice.gouv.fr
27307: fr.glee.wikia.com
12619: youwatch.org
77: i1.ytimg.com
879: r1---sn-gxo5uxg-jqbe.googlevideo.com
81: r4---sn-gxo5uxg-jqbe.googlevideo.com
3000: vk.com
```

not Alice

```
778: www.ncbi.nlm.nih.gov
780: blast.ncbi.nlm.nih.gov
812: mail.google.com
782: annotathon.org
786: www.phylogeny.fr
55: safebrowsing-cache.google.com
56: safebrowsing.clients.google.com
570: plus.google.com
```

Среди найденных сайтов имеются такие, которые в результате дополнительной проверки оказались неинформативными (Alice посещала их всего в нескольких сессиях) и в дальнейшем эти сайты (263, 25383) не использовались при построении признаков.

Видим, что Alice довольно часто использует французские сайты, возможно получится выделить подходящий признак.

1. Встречается ли домен 'fr' в названии сайта

В предыдущем пункте было обнаружено, что в некоторых уникальных для Alice сайтах иногда встречается домен 'fr'. Следует сравнить частоту появления этого домена в сайтах Alice и в сайтах остальных пользователей.

In [45]:
```
def hist_for_counted_words(df, pattern, sites_dict, density=True):
    ''' Строит гистограммы для частот встреченных сайтов в сессии,
        с подстрокой 'pattern' '''

    def search_and_sub(df, pattern):
        import copy
        new_df = copy.copy(df)

        sites = ['site%s' % i for i in range(1, 11)]
        for site in sites:
            new_df[site] = new_df[site].apply(lambda x: 1 if re.search(pattern, str(x)) else 0)

        return new_df

    print(f'Поиск: "{pattern}"')

    sites = ['site%s' % i for i in range(1, 11)]
    sites_df = df[sites].fillna(0).astype('int').applymap(lambda x: sites_dict[x])
    sites_df['target'] = df['target']

    sites_df = search_and_sub(sites_df, pattern)
    sites_df['count'] = sites_df[sites].values.sum(axis=1)

    plt.subplots(1, 2, figsize = (15, 6))

    plt.subplot(1, 2, 1)
    ax = sites_df[sites_df['target'] == 1]['count'].hist(range=(1, 11), density=density)
    ax.set(title='Alice',
           xlabel='number of occurrences')

    plt.subplot(1, 2, 2)
    ax = sites_df[sites_df['target'] == 0]['count'].hist(range=(1, 11), density=density)
    ax.set(title='not Alice',
           xlabel='number of occurrences')
```

In [46]:
```
hist_for_counted_words(train_df, '.fr', reversed_dict, density=False)
```

```
Поиск: ".fr"
```

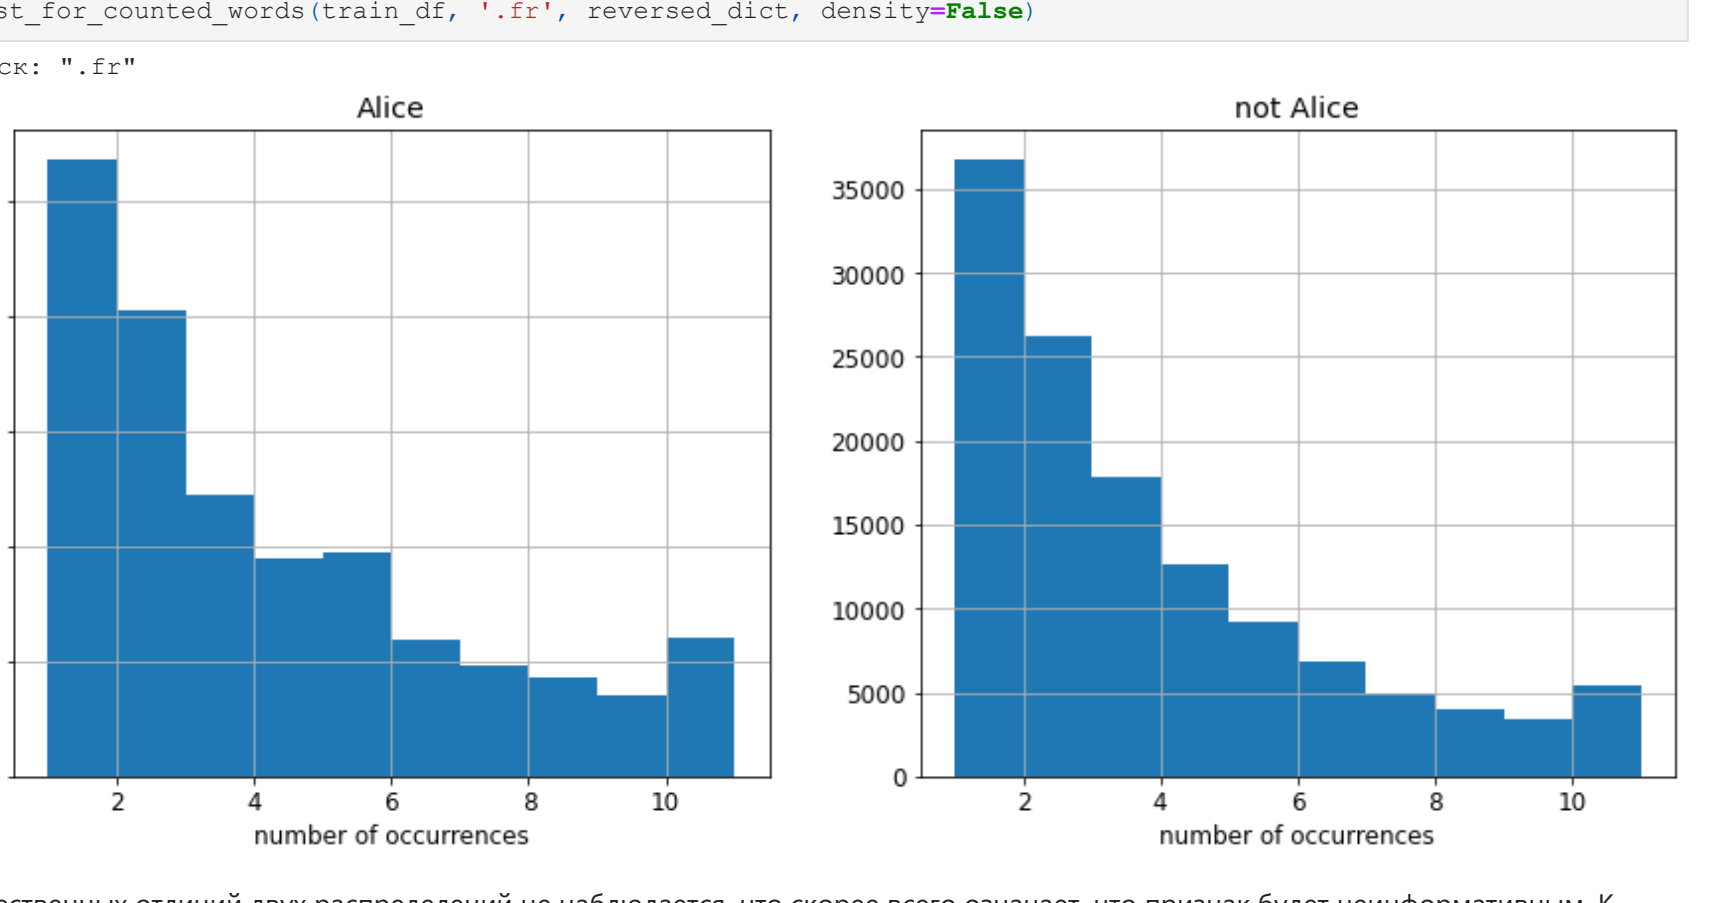

Существенных отличий двух распределений не наблюдается, что скорее всего означает, что признак будет неинформативным. К слову, найти подстроку, по которой можно было бы построить хороший признак, так и не представилось возможным.

В следующем разделе найденные закономерности будут применены для добавления новых признаков к тренировочному и тестовому наборам данных.

Обучение моделей (3)

В этом блокноте используются файлы, полученные при помощи предыдущих блокнотов (тренировочный и тестовый наборы данных). Наборы векторизуются, к полученным разреженным матрицам добавляются новые признаки, а затем на полученных данных обучается логистическая регрессия и применяется для классификации тестовых сессий.

Содержание

Загрузка предподготовленных данных

In [1]:
```
import os
import warnings
warnings.filterwarnings('ignore')

from tqdm import tqdm_notebook
import pickle

import numpy as np
import pandas as pd

import scipy.sparse as sp

from sklearn.model_selection import TimeSeriesSplit, cross_val_score, GridSearchCV
from sklearn.linear_model import (SGDClassifier, LogisticRegression,
                                  LogisticRegressionCV)
from sklearn.metrics import roc_auc_score, accuracy_score
from sklearn.feature_extraction.text import CountVectorizer, TfidfVectorizer

PATH_TO_DATASET = os.path.join('intermediate_data', 'test_train')
PATH_TO_DICT = os.path.join('initial_data', 'site_dict')

def write_to_submission_file(predicted_labels, out_file,
                             target='target', index_label="session_id"):
    ''' Записывает файл для посылки в Kaggle '''

    predicted_df = pd.DataFrame(predicted_labels,
                                index = np.arange(1, predicted_labels.shape[0] + 1),
                                columns=[target])
    predicted_df.to_csv(out_file, index_label=index_label)
```

In [2]:
```
with open(os.path.join(PATH_TO_DATASET, 'train_s10_w10_m30_final.pkl'), 'rb') as f:
    train_df = pickle.load(f)

with open(os.path.join(PATH_TO_DATASET, 'test_s10_w10_m30_final.pkl'), 'rb') as f:
    test_df = pickle.load(f)

train_df = train_df.sort_values(by=['year', 'month', 'day', 'time'])
```

In [3]:
```
train_test_df = pd.concat([train_df, test_df])
train_test_df_sites = train_test_df[['site%d' % i for i in range(1, 11)]].fillna(0).astype('int')
y_train = train_df['target'].astype('int').values
```

Применение CountVectorizer и TfidfVectorizer

In [48]:
```
sites = ['site%s' % i for i in range(1, 11)]

train_df[sites].fillna(0).astype('int').to_csv(os.path.join('intermediate_data', 'train_sessions_text_cnt.txt')
                                                sep=' ',
                       index=None, header=None)
test_df[sites].fillna(0).astype('int').to_csv(os.path.join('intermediate_data', 'test_sessions_text_cnt.txt'),
                                               sep=' ',
                       index=None, header=None)

with open(os.path.join(PATH_TO_DICT, 'site_dict.pkl'), 'rb') as file:
    sites_dict = pickle.load(file)
reversed_dict = {v: k for k, v in sites_dict.items()}
reversed_dict[0] = '0'

train_df[sites].fillna(0).astype('int').applymap(
    lambda x: reversed_dict[x]).to_csv(os.path.join('intermediate_data', 'train_sessions_text_tfidf.txt'), sep=
    index=None, header=None)
test_df[sites].fillna(0).astype('int').applymap(
    lambda x: reversed_dict[x]).to_csv(os.path.join('intermediate_data', 'test_sessions_text_tfidf.txt'), sep='
    index=None, header=None)
```

In [49]:
```
%%time
cnt_vectorizer = CountVectorizer(ngram_range=(1, 3), max_features=50000)
tfidf_vectorizer = TfidfVectorizer(ngram_range=(1, 5), max_features=100000, tokenizer=lambda s: s.split())
with open(os.path.join('intermediate_data', 'train_sessions_text_cnt.txt')) as inp_train_file:
    X_train = cnt_vectorizer.fit_transform(inp_train_file)
with open(os.path.join('intermediate_data', 'train_sessions_text_tfidf.txt')) as inp_train_file:
    X_train_tfidf = tfidf_vectorizer.fit_transform(inp_train_file)
with open(os.path.join('intermediate_data', 'test_sessions_text_cnt.txt')) as inp_test_file:
    X_test = cnt_vectorizer.transform(inp_test_file)
with open(os.path.join('intermediate_data', 'test_sessions_text_tfidf.txt')) as inp_test_file:
    X_test_tfidf = tfidf_vectorizer.transform(inp_test_file)
```

```
Wall time: 35.6 s
```

In [50]:
```
cnt_vectorizer.get_feature_names()[:10]
```

Out[50]:
```
['10',
 '10 1086',
 '10 11',
 '10 11 11',
 '10 11 12',
 '10 11 14',
 '10 11 15',
 '10 11241',
 '10 1199',
 '10 12']
```

In [51]:
```
tfidf_vectorizer.get_feature_names()[:10]
```

Out[51]:
```
['0',
 '0 0',
 '0 0 0',
 '0 0 0 0',
 '0 0 0 0 0',
 '0.academia-assets.com',
 '0.docs.google.com',
 '0.docs.google.com 0',
 '0.docs.google.com 0 0',
 '0.docs.google.com 0 0 0']
```

Функции для добавления фичей

In [8]:
```
def add_time_features(df, X_sparse):
    ''' Добавляет индикаторы (4 признака) утра, дня, вечера и ночи '''

    hour = df['start_hour']
    morning = ((hour >= 7) & (hour <= 11)).astype('int')
    day = ((hour >= 12) & (hour <= 18)).astype('int')
    evening = ((hour >= 19) & (hour <= 23)).astype('int')
    night = ((hour >= 0) & (hour <= 6)).astype('int')
    X = sp.hstack([X_sparse, morning.values.reshape(-1, 1),
                   day.values.reshape(-1, 1), evening.values.reshape(-1, 1),
                   night.values.reshape(-1, 1)])
    return X
```

In [9]:
```
def add_session_timespan(df, X_sparse):
    ''' Добавляет продолжительность сессии в секундах (1 признак) '''

    session_timespan = df['session_timespan']
    X = sp.hstack([X_sparse, session_timespan.values.reshape(-1, 1)])
    return X
```

In [10]:
```
def feature_short_session(df, X_sparse, time_min=0, time_max=3):
    ''' Добавляет индикаторы короткой сессии (от 0 до 2 секунд)
    (1 признак)'''

    def short_session(x):
        if ((x >= time_min) and (x < time_max)):
            return 1
        return 0

    times = df['session_timespan']
    X = sp.hstack([X_sparse, times.apply(short_session).values.reshape(-1, 1)])
    return X


def feature_middle_session(df, X_sparse, time_min=3, time_max=9):
    ''' Добавляет индикаторы средней сессии (от 3 до 6 секунд)
    (1 признак)'''

    def middle_session(x):
        if ((x >= time_min) and (x < time_max)):
            return 1
        return 0

    times = df['session_timespan']
    X = sp.hstack([X_sparse, times.apply(middle_session).values.reshape(-1, 1)])
    return X
```

In [11]:
```
def add_top_sites(df, X_sparse, list_of_sites={3000, 2080, 27307}):
    ''' Добавляет индикаторы (1 признак) нескольких сайтов, которые Alice
    использует замето чаще, чем остальные люди '''

    sites = df[['site%s' % i for i in range(1, 11)]].values
    result = [0]*sites.shape[0]

    for i, session in enumerate(sites):
        for site in session:
            if site in list_of_sites:
                result[i] += 1

    X = sp.hstack([X_sparse, np.array(result).reshape(-1, 1)])
    return X
```

In [12]:
```
def add_reverse_top_sites(df, X_sparse, list_of_sites={55, 56, 570,
                                                       778, 780, 782,
                                                       786, 812}):
    ''' Добавляет индикаторы (1 признак) нескольких сайтов, которые Alice
    использует замето реже, чем остальные люди '''

    sites = df[['site%s' % i for i in range(1, 11)]].values
    result = [0]*sites.shape[0]

    for i, session in enumerate(sites):
        for site in session:
            if site in list_of_sites:
                result[i] += 1

    X = sp.hstack([X_sparse, np.array(result).reshape(-1, 1)])
    return X
```

In [13]:
```
''' Оказалось, что признак плохой и приводит к переобучению '''

def add_start_hour(df, X_sparse):
    ''' Добавляет час начала сессии (1 признак) '''

    start_hour = df['start_hour']
    X = sp.hstack([X_sparse, start_hour.values.reshape(-1, 1)])
    return X
```

In [14]:
```
def add_day_of_week(df, X_sparse):
    ''' Добавляет день начала сессии (1 признак) '''

    day_of_week = df['day_of_week']
    X = sp.hstack([X_sparse, day_of_week.values.reshape(-1, 1)])
    return X
```

Далее закомментированы определения функций, добавляющих плохие признаки.

In [15]:
```
'''
def add_num_of_unique(df, X_sparse):
    # Добавляет количество уникальных сайтов в сессии (1 признак)

    num_of_unique = df['#unique_sites']
    X = sp.hstack([X_sparse, num_of_unique.values.reshape(-1, 1)])
    return X
'''
```

Out[15]:
```
"\ndef add_num_of_unique(df, X_sparse):\n    # Добавляет количество уникальных сайтов в сессии (1 признак)\n\n
   num_of_unique = df['#unique_sites']\n    X = sp.hstack([X_sparse, num_of_unique.values.reshape(-1, 1)])\n
return X\n"
```

In [16]:
```
'''
from sklearn.preprocessing import StandardScaler

def add_session_timespan_scaled(df, X_sparse):
    session_timespan = df['session_timespan_scaled']
    X = sp.hstack([X_sparse, session_timespan.values.reshape(-1, 1)])
    return X

scaler_sess_timespan = StandardScaler(with_std=False, with_mean=False)
train_df['session_timespan_scaled'] = scaler_sess_timespan.fit_transform(train_df['session_timespan'].values.re
test_df['session_timespan_scaled'] = scaler_sess_timespan.transform(test_df['session_timespan'].values.reshape
'''
```

Out[16]:
```
"\nfrom sklearn.preprocessing import StandardScaler\n\ndef add_session_timespan_scaled(df, X_sparse):\n    sess
ion_timespan = df['session_timespan_scaled']\n    X = sp.hstack([X_sparse, session_timespan.values.reshape(-1,
1)])\n    return X\n    \nscaler_sess_timespan = StandardScaler(with_std=False, with_mean=False)\ntrain_df['ses
sion_timespan_scaled'] = scaler_sess_timespan.fit_transform(train_df['session_timespan'].values.reshape(-1, 1))
\ntest_df['session_timespan_scaled'] = scaler_sess_timespan.transform(test_df['session_timespan'].values.reshap
e(-1, 1))\n"
```

Применение преобразованных наборов данных для классификации

В данном разделе были обучены LogisticRegressionCV на двух тренировочных наборах данных:

- К тренировочным и тестовым наборам, преобразованным при помощи CountVectorizer и TfidfVectorizer добавлены индикаторы утра, дня, вечера и ночи.
- Определены показатели метрики roc-auc.
- Обученные LogisticRegressionCV с найденным коэффициентом регуляризации применены для классификации сессий в соответствующих тестовых наборах данных.
- Отправлены посылки в соревновании на Kaggle.
- Сделаны выводы.

In [17]:
```
time_split = TimeSeriesSplit(n_splits=10) # для валидации
y_train = train_df['target'].astype('int').values
```

In [18]:
```
X_train_cnt_1f = add_time_features(train_df.fillna(0), X_train)
X_test_cnt_1f = add_time_features(test_df.fillna(0), X_test)

X_train_tfidf_1f = add_time_features(train_df.fillna(0), X_train_tfidf)
X_test_tfidf_1f = add_time_features(test_df.fillna(0), X_test_tfidf)
```

In [19]:
```
%%time
logit_c_values = np.linspace(0.1, 5, 10)

logit_grid_searcher_cnt = LogisticRegressionCV(Cs=logit_c_values,
                                               solver='liblinear',
                                               random_state=17,
                                               cv=time_split,
                                               n_jobs=-1, scoring='roc_auc',
                                               verbose=3,
                                               max_iter=2000)
logit_grid_searcher_cnt.fit(X_train_cnt_1f, y_train)
```

```
[Parallel(n_jobs=-1)]: Using backend LokyBackend with 12 concurrent workers.
[Parallel(n_jobs=-1)]: Done   3 out of  10 | elapsed:   38.2s remaining:  1.5min
[Parallel(n_jobs=-1)]: Done   7 out of  10 | elapsed:  1.5min remaining:   39.6s
[Parallel(n_jobs=-1)]: Done  10 out of  10 | elapsed:  2.5min finished
[LibLinear]Wall time: 2min 39s
```

Out[19]:
```
LogisticRegressionCV(Cs=array([0.1       , 0.64444444, 1.18888889, 1.73333333, 2.27777778,
       2.82222222, 3.36666667, 3.91111111, 4.45555556, 5.        ]),
                     cv=TimeSeriesSplit(max_train_size=None, n_splits=10),
                     max_iter=2000, n_jobs=-1, random_state=17,
                     scoring='roc_auc', solver='liblinear', verbose=3)
```

In [20]:
```
logit_mean_cv_scores_cnt = logit_grid_searcher_cnt.scores_[1].mean(axis=0)
print(logit_mean_cv_scores_cnt.max(),
      logit_grid_searcher_cnt.Cs_[logit_mean_cv_scores_cnt.argmax()])
```

```
0.9166806003300598 0.6444444444444445
```

In [21]:
```
logit_test_pred_cnt= logit_grid_searcher_cnt.predict_proba(X_test_cnt_1f)[:, 1]
write_to_submission_file(logit_test_pred_cnt, 'submit_cnt.csv') # 0.93980
```

In [22]:
```
%%time
logit_c_values = np.linspace(0.1, 5, 10)

logit_grid_searcher_tfidf = LogisticRegressionCV(Cs=logit_c_values,
                                                 solver='liblinear',
                                                 random_state=17,
                                                 cv=time_split,
                                                 n_jobs=-1, scoring='roc_auc',
                                                 verbose=3,
                                                 max_iter=2000)
logit_grid_searcher_tfidf.fit(X_train_tfidf_1f, y_train)
```

```
[Parallel(n_jobs=-1)]: Using backend LokyBackend with 12 concurrent workers.
[Parallel(n_jobs=-1)]: Done   3 out of  10 | elapsed:   16.6s remaining:   38.8s
[Parallel(n_jobs=-1)]: Done   7 out of  10 | elapsed:   29.2s remaining:   12.5s
[Parallel(n_jobs=-1)]: Done  10 out of  10 | elapsed:   36.2s finished
[LibLinear]Wall time: 39.6 s
```

Out[22]:
```
LogisticRegressionCV(Cs=array([0.1       , 0.64444444, 1.18888889, 1.73333333, 2.27777778,
       2.82222222, 3.36666667, 3.91111111, 4.45555556, 5.        ]),
                     cv=TimeSeriesSplit(max_train_size=None, n_splits=10),
                     max_iter=2000, n_jobs=-1, random_state=17,
                     scoring='roc_auc', solver='liblinear', verbose=3)
```

In [23]:
```
logit_mean_cv_scores_tfidf = logit_grid_searcher_tfidf.scores_[1].mean(axis=0)
print(logit_mean_cv_scores_tfidf.max(),
      logit_grid_searcher_tfidf.Cs_[logit_mean_cv_scores_tfidf.argmax()])
```

```
0.9245491008379615 4.455555555555556
```

In [24]:
```
logit_test_pred_tfidf = logit_grid_searcher_tfidf.predict_proba(X_test_tfidf_1f)[:,
1]
write_to_submission_file(logit_test_pred_tfidf, 'submit_tfidf.csv') # 0.94368
```

Поскольку более высокому roc-auc в leaderboard у TfidfVectorizer соответствует более высокое значение данной метрики и на валидации, то можно сделать вывод об удачном выборе метода валидации. В дальнейшем будут использоваться наборы данных, преобразованные при помощи TfidfVectorizer.

In [25]:
```
X_train_1f = X_train_tfidf_1f
X_test_1f = X_test_tfidf_1f
```

Применение новых фичей для классификации

In [26]:
```
X_train_2f = add_session_timespan(train_df, X_train_1f)
X_test_2f = add_session_timespan(test_df, X_test_1f)
```

In [27]:
```
X_train_3f = feature_short_session(train_df, X_train_2f)
X_test_3f = feature_short_session(test_df, X_test_2f)
```

In [28]:
```
X_train_4f = add_top_sites(train_df, X_train_3f)
X_test_4f = add_top_sites(test_df, X_test_3f)
```

In [29]:
```
X_train_5f = add_reverse_top_sites(train_df, X_train_4f)
X_test_5f = add_reverse_top_sites(test_df, X_test_4f)
```

In [30]:
```
X_train_6f = feature_middle_session(train_df, X_train_5f)
X_test_6f = feature_middle_session(test_df, X_test_5f)
```

In [44]:
```
# Пример кросс-валидации
logit_c_values = np.linspace(3, 5, 50)

logit_final = LogisticRegressionCV(Cs=logit_c_values,
                                   solver='liblinear',
                                   random_state=17,
                                   cv=time_split,
                                   n_jobs=-1, scoring='roc_auc',
                                   verbose=3,
                                   penalty='l2')
logit_final.fit(X_train_6f, y_train)

logit_mean_cv_scores = logit_final.scores_[1].mean(axis=0)
print(logit_mean_cv_scores.max(), logit_final.Cs_[logit_mean_cv_scores.argmax()])

# 0.9321137656775317 3.6530612244897958 # 0.95044
```

```
[Parallel(n_jobs=-1)]: Using backend LokyBackend with 12 concurrent workers.
[Parallel(n_jobs=-1)]: Done   3 out of  10 | elapsed:  4.1min remaining:  9.6min
[Parallel(n_jobs=-1)]: Done   7 out of  10 | elapsed:  6.8min remaining:  2.9min
[Parallel(n_jobs=-1)]: Done  10 out of  10 | elapsed:  9.4min finished
[LibLinear]0.9321137656775317 3.6530612244897958
```

In [45]:
```
logit_final = LogisticRegression(C=3.6530612244897958,
                                 solver='liblinear',
                                 random_state=17,
                                 n_jobs=-1,
                                 penalty='l2')
logit_final.fit(X_train_6f, y_train)
```

Out[45]:
```
LogisticRegression(C=3.6530612244897958, n_jobs=-1, random_state=17,
                   solver='liblinear')
```

In [46]:
```
logit_final_cv_score = cross_val_score(logit_final,
                                       X_train_6f,
                                       y_train,
                                       scoring='roc_auc',
                                       cv=time_split).mean()
print('final cv score:', logit_final_cv_score)
```

```
final cv score: 0.9310553238208839
```

In [47]:
```
logit_test_pred_final = logit_final.predict_proba(X_test_6f)[:, 1]
write_to_submission_file(logit_test_pred_final, 'subm_logit_final.csv')
```

Заключение

Score на публичной части тестовых данных: **0.95044**. Результат далёк от лучших позиций в рейтинге, однако целью проделанной работы являлось знакомство с площадкой Kaggle, получение навыков обработки и визуализации данных, а также изучение основ машинного обучения.

В качестве шагов для улучшения качества построенной модели в дальнейшем будут проделаны следующие шаги:

- применение других методов машинного обучения (бустинг над решающими деревьями, метод ближайших соседей);
- улучшения в схеме кросс-валидации (замечено, что не всегда рост roc-auc на кросс-валидации соответствует росту roc-auc на публичной части тестовых данных);
- проверка на переобученность модели при использовании отдельных признаков.

Дополнительная глава (4)

В данном блокноте собраны функции, позволяющие обработать наборы данных о посещениях сайтов пользователями. Сырые данные для этой задачи представляют собой cvs-файлы с данными о веб-сёрфинге отдельного пользователя в следующем виде:

```
timestamp,site
2013-11-15 11:40:34,google.com
...
```

Требуется объединить коллекцию таких файлов в одну большую таблицу. При этом в полученной таблице отдельные строки - это сессии - последовательности из нескольких сайтов. Решение должно поддерживать создание таблицы с разной длиной сессии, а также с различной шириной окна.

Пример: для длины сессии 10 и ширины окна 7 файл из 30 записей породит не 3 сессии (1-10, 11-20, 21-30), а 5 (1-10, 8-17, 15-24, 22-30, 29-30). При этом в предпоследней сессии будет один ноль, а в последней – 8 нолей.

Важное замечание! Задача, поставленная в этом разделе не связана напрямую с решением предложенной организаторами соревнования на Kaggel. Задача решалась исключительно в факультативных целях и для того, чтобы осознать необходимость оптимизации кода.

In [1]:
```
import warnings
warnings.filterwarnings('ignore')
from glob import glob
import os
import pickle
from tqdm import tqdm
import numpy as np
import pandas as pd

import itertools
import re
import scipy.sparse as sp
import time

PATH_TO_DATA = os.path.join('initial_data', 'users')
PATH_TO_SITE_FREQ = os.path.join('initial_data', 'site_freq')
```

Посмотрим на файл с данными на примере пользователя user0128 из коллекции с 10 пользователями.

In [2]:
```
user31_data = pd.read_csv(os.path.join(PATH_TO_DATA, '10users/user0128.csv'))
user31_data.head()
```

Out[2]:

	timestamp	site
0	2013-11-15 13:46:03	fpdownload2.macromedia.com
1	2013-11-15 13:46:13	mail.google.com
2	2013-11-15 13:46:13	www.gmail.com
3	2013-11-15 13:46:25	accounts.google.com
4	2013-11-15 13:46:28	accounts.youtube.com

Основная функция в этом разделе - это функция

```
prepare_sparse_train_set_window.
```

Она принимает на вход путь к коллекции csv-файлов с данными по каждому пользователю, путь к заранее подготовленному словарю сайтов, а также параметры session_length и window_size, отвечающие за длину сессии и размер окна соответственно.

Для удобства, отдельно определена функция

```
make_sparse_data,
```

которая помогает на основе таблицы с сессиями создаёт матрицу частот в разреженном формате.

In [3]:
```
def make_sparse_data(data):
    ''' Принимает на вход DataFrame с сессиями и
    возвращает разреженную матрицу частот'''

    indptr = [0]
    indices = []
    sparse_data = []
    for row in tqdm(data):
        val, cnt = np.unique(row[row != 0], return_counts=True)
        indptr.append(indptr[-1] + len(val))
        for v, c in zip(val, cnt):
            indices.append(v - 1)
            sparse_data.append(c)

    return np.uint64(sparse_data),  np.uint64(indices), np.uint64(indptr)
```

In [4]:
```python
def prepare_data_set_window(path_to_csv_files, site_freq_path,
                            session_length=10, window_size=10):
    ''' Подготавливает набор данных. Сырые данных хранятся в path_to_csv_files.
    Возвращает матрицу частот в разреженном формате, вектор с user_id и DataFrame
    с соответствующим набором сессий'''

    with open(site_freq_path, 'rb') as file:
        site_freq_dict = pickle.load(file)

    data = []

    list_of_files = glob(os.path.join(path_to_csv_files, '*'))
    for path_to_user in list_of_files:
        user_id = int(re.sub(r'\b0+', '', path_to_user[-8:-4], 1)) # user0001 --> 1
        sites_array = pd.read_csv(path_to_user)['site'].map(lambda x: site_freq_dict[x][0]).values.tolist()
        n = len(sites_array)
        ind = 0
        while True:
            if ind + session_length > n-1:
                data.append(sites_array[ind:n] + [0 for _ in range(ind + session_length - n)] + [user_id])
            else:
                data.append(sites_array[ind:ind+session_length] + [user_id])
            ind += window_size
            if ind >= n:
                break

    feature_names=[f'site{i}' for i in range(1, session_length + 1)] + ['target']
    data_df = pd.DataFrame(data, columns=feature_names)
    target = np.array(data_df['target'].values, dtype='int16')

    '''Создание и заполнение разреженной матрицы частот'''
    X, y = data_df.iloc[:, :-1].values, data_df.iloc[:, -1].values
    sparse_data = sp.csr_matrix(make_sparse_data(X), dtype='int8')

    return sparse_data, target, data_df
```

In [5]:
```python
%%time
X_sparse_10users_s10_w7, y_10users_s10_w7, df = prepare_data_set_window(os.path.join(PATH_TO_DATA,'150users'),
                                                      os.path.join(PATH_TO_SITE_FREQ,'site_freq_150users.pkl'),
                                                      session_length=10, window_size=7)
```

```
100%|██████████████████████████████| 195712/195712 [00:06<00:00, 30078.11it/s]
Wall time: 9.7 s
```

Обработаем наборы данных для 10 и 150 пользователей и сохраним разреженные матрицы в формате

X_sparse_{кол-во пользователей}users_s{длина сессии}_w{ширина окна}.pkl

Также сохраним id пользователей в формате

y_{кол-во пользователей}users_s{длина сессии}_w{ширина окна}.pkl

In [6]:
```python
%%time
for num_users in [10, 150]:
    for window_size, session_length in itertools.product([10, 7, 5], [15, 10, 7, 5]):
        if window_size <= session_length:
            X_sparse, y, _ = prepare_data_set_window(os.path.join(PATH_TO_DATA,'{}users'.format(num_users)),
                                                     os.path.join(PATH_TO_SITE_FREQ,'site_freq_{}users.p
                                                     session_length=session_length, window_size=window_s
            with open(os.path.join(PATH_TO_DATA,
                                   'X_sparse_{}users_s{}_w{}.pkl'.format(num_users,
                                                                          session_length,
                                                                          window_size)), 'wb') as X_pkl:
                pickle.dump(X_sparse, X_pkl)
            with open(os.path.join(PATH_TO_DATA,
                                   'y_{}users_s{}_w{}.pkl'.format(num_users,
                                                                   session_length,
                                                                   window_size)), 'wb') as y_pkl:
                pickle.dump(y, y_pkl)
```

```
100%|██████████████████████████████| 14061/14061 [00:00<00:00, 29978.99it/s]
100%|██████████████████████████████| 14061/14061 [00:00<00:00, 30358.40it/s]
100%|██████████████████████████████| 20087/20087 [00:00<00:00, 30053.95it/s]
100%|██████████████████████████████| 20087/20087 [00:00<00:00, 30959.09it/s]
100%|██████████████████████████████| 20087/20087 [00:00<00:00, 31821.81it/s]
100%|██████████████████████████████| 28118/28118 [00:00<00:00, 29757.74it/s]
100%|██████████████████████████████| 28118/28118 [00:00<00:00, 30645.10it/s]
100%|██████████████████████████████| 28118/28118 [00:00<00:00, 31796.35it/s]
100%|██████████████████████████████| 28118/28118 [00:00<00:00, 32044.24it/s]
100%|██████████████████████████████| 137019/137019 [00:04<00:00, 28681.56it/s]
100%|██████████████████████████████| 137019/137019 [00:04<00:00, 29834.93it/s]
100%|██████████████████████████████| 195712/195712 [00:06<00:00, 29247.96it/s]
100%|██████████████████████████████| 195712/195712 [00:06<00:00, 30443.86it/s]
100%|██████████████████████████████| 195712/195712 [00:06<00:00, 30196.01it/s]
100%|██████████████████████████████| 273957/273957 [00:09<00:00, 29314.67it/s]
100%|██████████████████████████████| 273957/273957 [00:09<00:00, 30205.28it/s]
100%|██████████████████████████████| 273957/273957 [00:08<00:00, 31819.93it/s]
100%|██████████████████████████████| 273957/273957 [00:08<00:00, 32502.36it/s]
Wall time: 1min 39s
```

Теперь, когда подготовлены таблицы с сессиями в различных форматах (с различными session_length и window_size), можно попробовать натренировать модели (например, логистическую регрессию) на различных наборах данных. Тренировать модели на данных 150 пользователей долго, поэтому для примера, воспользуемся датасетами для 10 пользователей.

In [7]:
```python
from sklearn.linear_model import LogisticRegressionCV
from sklearn.model_selection import StratifiedKFold

def logit_cv(logit_c_values, path_to_X_pickle, path_to_y_pickle):
    ''' Тренирует LogisticRegressionCV с параметром из logit_c_values
    на данных из path_to_X_pickle и path_to_y_pickle'''

    with open(path_to_X_pickle, 'rb') as X_sparse_users_pkl:
        X_sparse_users = pickle.load(X_sparse_users_pkl)
    with open(path_to_y_pickle, 'rb') as y_pkl:
        y = pickle.load(y_pkl)

    logit_c_values = np.linspace(0.5, 4, 5)

    logit_grid_searcher = LogisticRegressionCV(Cs=logit_c_values,
                                               multi_class='multinomial',
                                               random_state=17,
                                               cv=StratifiedKFold(n_splits=3, shuffle=True, random_state=17),
                                               n_jobs=-1)
    logit_grid_searcher.fit(X_sparse_users, y)

    return logit_grid_searcher

logit_c_values = np.linspace(0.5, 6, 5)
```

In [8]:
```python
all_logit_searchers = []

for window_size, session_length in itertools.product([10, 7, 5], [15, 10, 7, 5]):
    if window_size <= session_length:
        path_to_X_pickle = os.path.join(PATH_TO_DATA,
                                        f'X_sparse_10users_s{session_length}_w{window_size}.pkl')
        path_to_y_pickle = os.path.join(PATH_TO_DATA,
                                        f'y_10users_s{session_length}_w{window_size}.pkl')

        logit_grid_searcher = logit_cv(logit_c_values, path_to_X_pickle, path_to_y_pickle)

        all_logit_searchers.append(logit_grid_searcher)

        print(f'session_length = {session_length}, window_size = {window_size}')
        logit_mean_cv_scores = logit_grid_searcher.scores_[31].mean(axis=0)
        print('max cv score for user0031: ', logit_mean_cv_scores.max())
        print('best C: ', logit_grid_searcher.Cs_[logit_mean_cv_scores.argmax()])
```

```
session_length = 15, window_size = 10
max cv score for user0031:  0.8381338453879525
best C:  1.375
session_length = 10, window_size = 10
max cv score for user0031:  0.7763316976032999
best C:  1.375
session_length = 15, window_size = 7
max cv score for user0031:  0.8637924201474676
best C:  3.125
session_length = 10, window_size = 7
max cv score for user0031:  0.8123162268245263
best C:  1.375
session_length = 7, window_size = 7
max cv score for user0031:  0.7587494040411881
best C:  3.125
session_length = 15, window_size = 5
max cv score for user0031:  0.8841665915712135
best C:  3.125
session_length = 10, window_size = 5
max cv score for user0031:  0.8334162722580608
best C:  4.0
session_length = 7, window_size = 5
max cv score for user0031:  0.7878939587540709
best C:  3.125
session_length = 5, window_size = 5
max cv score for user0031:  0.7368590432312572
best C:  3.125
```

Наилучшее качество на кросс-валидации оказалось у датасета session_length = 15, window_size = 5. В дальнейшем можно проверить то же самое на более крупных датасетах, например на датасете 3000users. Но это выходит за рамки дополнительной главы, которая на этом заканчивается.